

Predicción de la generación fotovoltaica industrial mediante análisis multivariante y funcional: instalación del taller de módulos y reparaciones de Navantia Ferrol

Estudiante: Hugo Balado Mosquera

Dirección: Ana López Cheda

Manuel Oviedo de la Fuente

A Coruña, julio de 2026.

Al niño que fui, que se merecía llegar hasta aquí.

Agradecimientos

A Navantia, por proporcionarme el soporte para desarrollar este proyecto, con mención especial a David Roca por sentar las bases y a Rafa Morgade, por motivarme a hacerlo.

A mis tutores, Ana y Manuel, no solo por vuestra guía académica, sino por vuestra cercanía y paciencia.

A Coruña y Białystok, los escenarios de mi vida universitaria. A día de hoy tengo la certeza de saber que he tomado el camino correcto. Gracias a estas etapas he podido conocer a gente que me ha hecho valorar lo importante que es estar bien rodeado.

A Hegoa, porque fuiste mi ejemplo a seguir y una gran motivación durante este camino a pesar de los kilómetros que nos separan. Gracias por sacar mi mejor versión.

A Maru y a Moncho, por vuestra ayuda durante estos años.

A mis tíos, David e Iria, y a mis primos, Iago y Mencía. Esa familia que uno tiene la suerte de elegir. Gracias por haber visto siempre algo especial en mí.

A mi abuela Maruja, por mantenerte ahí a pesar de todo y porque contigo nunca falta de nada.

A mis abuelos, Gerardo y Marité, a quienes intento devolver el cariño lo mejor que puedo. Gracias por escucharme siempre con tanta ilusión, la misma que siento yo al saber que vais a ver cómo cierro esta etapa.

A mi hermana, Jimena, por hacerme madurar tan pronto, y porque desde que naciste solo quise una cosa: servirte de espejo. Quiero que veas en estas páginas algo más que un trabajo académico.

Y por último, a mis padres, porque este título lleva vuestro apellido, pero sobre todo, vuestro esfuerzo. Todo lo que soy y todo lo que espero ser, os lo debo a vosotros.

Resumen

Este Trabajo de Fin de Grado aborda el modelado y la predicción de la generación fotovoltaica de la instalación industrial del taller de módulos y reparaciones de Navantia en Ferrol, compuesta por tres inversores monitorizados mediante un sistema SCADA. El objetivo principal es comparar la capacidad predictiva del análisis multivariante clásico y el análisis de datos funcionales, combinando registros de potencia con resolución diezminutal e información meteorológica de MeteoGalicia.

Abstract

This Bachelor's Thesis addresses the modeling and prediction of photovoltaic power generation at the industrial facility of the modules and repairs workshop of Navantia in Ferrol, which is composed of three inverters monitored through a SCADA system. The main objective is to compare the predictive capability of classical multivariate analysis and functional data analysis, combining ten-minute resolution power records with meteorological information from MeteoGalicia.

Palabras clave:

- Análisis de datos funcionales
- Análisis multivariante
- Datos meteorológicos
- Energía fotovoltaica
- Modelado predictivo
- Navantia
- SCADA

Keywords:

- Functional data analysis
- Meteorological data
- Multivariate analysis
- Navantia
- Photovoltaic energy
- Predictive modeling
- SCADA

Índice general

1	Introducción	1
1.1	Contexto y motivación	1
1.2	Objetivos del TFG	3
1.2.1	Objetivo principal	4
1.2.2	Objetivos secundarios	4
1.3	Estructura de la memoria	5
2	Marco teórico	7
2.1	Conceptos fundamentales de energía fotovoltaica	7
2.1.1	Panel fotovoltaico	7
2.1.2	Inversor	8
2.1.3	Monitorización SCADA	8
2.2	Estado del arte	8
2.3	Análisis multivariante	9
2.3.1	Correlación	9
2.3.2	Detección de outliers: local outlier factor (LOF)	10
2.3.3	Análisis de componentes principales (PCA)	11
2.3.4	Escalamiento multidimensional (MDS)	12
2.3.5	Clasificación no supervisada: <i>clustering</i>	13
2.3.6	Modelos de regresión	15
2.4	Análisis de datos funcionales	19
2.4.1	El dato funcional: concepto y representación	19
2.4.2	Suavizado y representación en bases	20
2.4.3	Profundidad funcional y outliers	21
2.4.4	Análisis de componentes principales funcional	23
2.4.5	Regresión funcional	23

3	Metodología y planificación	26
3.1	Metodología de desarrollo (CRISP-DM)	26
3.2	Planificación temporal	27
3.3	Herramientas	28
3.3.1	Ecosistema de software	28
3.3.2	Infraestructura de hardware	28
3.4	Costes	28
3.4.1	Costes de personal	29
4	Datos y análisis exploratorio	30
4.1	Instalación fotovoltaica	30
4.2	Registros del SCADA	31
4.3	Datos meteorológicos: CIS Ferrol	32
4.4	Integración y preprocesamiento	33
4.4.1	Sincronización de zonas horarias	33
4.4.2	Regularización a intervalos de 10 minutos	34
4.4.3	Agregación diaria de variables	34
4.4.4	Exclusión de anomalías operativas	35
4.5	Estudio descriptivo	35
4.5.1	Análisis univariante	35
4.5.2	Análisis bivariante	39
4.5.3	Análisis de correlación	42
5	Análisis multivariante	44
5.1	Detección de outliers	44
5.2	Análisis de componentes principales (PCA)	45
5.2.1	PCA sobre los inversores	45
5.2.2	PCA sobre todas las variables	46
5.3	Escalamiento multidimensional	47
5.4	Análisis clustering	49
5.4.1	Clustering solo con potencia	49
5.4.2	Clustering con todas las variables	51
5.5	Modelos de regresión	55
5.5.1	Regresión lineal múltiple	55
5.5.2	Modelos no lineales: Random Forest	60
5.5.3	Comparativa de modelos	60

6	Análisis funcional	61
6.1	Representación funcional de los datos	61
6.2	Suavizado de las curvas funcionales	63
6.3	Medidas de profundidad y outliers funcionales	65
6.3.1	Elección del método y conjunto de curvas	65
6.3.2	Mediana y media recortada funcional	66
6.3.3	Estratificación estacional	67
6.4	Análisis de componentes principales funcional (FPCA)	69
6.4.1	Selección del número de componentes	69
6.4.2	Autofunciones e interpretación	70
6.5	Regresión funcional	72
6.5.1	Estrategia de modelización	72
6.5.2	Modelos funcionales simples	73
6.5.3	Modelo funcional múltiple	74
6.5.4	Diagnóstico del modelo final	76
7	Conclusiones y trabajo futuro	77
7.1	Situación final del trabajo	77
7.2	Trabajo futuro	78
7.3	Relación con el grado	79
A	Material adicional	82
A.1	Instalación y datos SCADA	82
A.2	Análisis multivariante	83
A.3	Análisis funcional	88
	Bibliografía	93

Índice de figuras

1.1	Paneles fotovoltaicos instalados sobre las cubiertas del taller de módulos y reparaciones. [Fuente: Navantia]	2
1.2	Vista aérea del astillero de Navantia en Ferrol desde el sistema SCADA de la factoría, con la localización de las instalaciones fotovoltaicas señalizada mediante iconos sobre las cubiertas correspondientes.	3
3.1	Diagrama de Gantt con la planificación temporal del proyecto.	27
4.1	Interfaz SCADA del sistema fotovoltaico del taller de reparaciones, con las lecturas en tiempo real de los tres inversores KACO y la potencia total generada.	31
4.2	Localización de la planta fotovoltaica de Navantia Ferrol (azul) y de la estación meteorológica CIS Ferrol de MeteoGalicia (naranja).	32
4.3	Análisis univariante de la potencia media diaria.	37
4.4	Distribución de las variables radiación y temperatura.	37
4.5	Distribución de las variables de humedad y precipitación.	38
4.6	Distribución de las variables de viento y presión atmosférica.	38
4.7	Relación de la potencia con los principales factores meteorológicos.	40
4.8	Relación de la potencia con variables de humedad y lluvia.	40
4.9	Relación de la potencia con la dinámica barométrica y eólica.	41
4.10	Correlación de Pearson.	42
4.11	Correlación de distancias.	42
5.1	Mapa de similitud entre variables mediante MDS clásico.	48
5.2	Representación de la suma de la variabilidad al cuadrado dentro de los grupos (WSS) y entre grupos (BSS) para la determinación del número óptimo de <i>clusters</i> en el análisis basado en la potencia generada.	50
5.3	Evolución temporal de la potencia media diaria segmentada por <i>clusters</i>	51

5.4	Representación de la suma de la variabilidad al cuadrado dentro de los grupos (WSS) y entre grupos (BSS) para la determinación del número óptimo de <i>clusters</i> .	52
5.5	Evolución temporal de la potencia media diaria segmentada por <i>clusters</i> .	53
5.6	Representación del clustering mediante las dos primeras componentes principales. Las elipses delimitan las fronteras de decisión para los tres grupos identificados.	54
5.7	Gráficos de componente más residuo. La línea discontinua azul representa el ajuste lineal del modelo; la línea rosa el suavizado no paramétrico.	57
5.8	Gráficos de diagnóstico del modelo seleccionado: residuos frente a valores ajustados, QQ-plot de residuos estandarizados, Scale-Location e influencia (residuos vs leverage).	58
6.1	Curvas funcionales diarias de las seis variables del <code>ldata_fv</code> , coloreadas por mes del año (azul = invierno, rojo = verano).	63
6.2	Curvas funcionales diarias de las seis variables tras el suavizado, coloreadas por mes del año (azul = invierno, rojo = verano).	65
6.3	Conjunto de las 432 curvas diarias de potencia coloreadas según su profundidad de Fraiman-Muniz.	67
6.4	Curvas diarias de potencia identificadas como outliers funcionales mediante análisis estratificado. Izquierda: outliers de invierno; Derecha: outlier de verano.	68
6.5	Primera y segunda autofunción del FPCA sobre las curvas de potencia suavizadas.	70
6.6	Primera y segunda autofunción del FPCA sobre las curvas de temperatura suavizadas.	71
6.7	$\hat{\beta}(t)$ del modelo M1a.	74
6.8	$\hat{\beta}(t)$ del modelo M2a.	74
6.9	Funciones parámetro estimadas $\hat{\beta}(t)$ del modelo M3 para las covariables de radiación (izquierda), temperatura (centro) y humedad relativa (derecha).	75
A.1	Inversores fotovoltaicos KACO BLUEPLANET 100 NX3 instalados en la planta. [Fuente: Documento interno]	82
A.2	Densidad de probabilidad de los scores LOF para la detección de outliers.	83
A.3	Matriz de correlaciones parciales de las variables continuas del modelo de regresión. Valores próximos a ± 1 indican dependencia lineal fuerte una vez controlado el efecto del resto de variables.	84
A.4	Potencia observada frente a potencia predicha por el modelo de regresión lineal múltiple seleccionado sobre el conjunto de prueba. La línea discontinua roja representa la predicción perfecta.	85

A.5	QQ-plot de los residuos del modelo seleccionado con banda de confianza al 95 %.	86
A.6	Importancia de variables del modelo Random Forest.	87
A.7	Potencia observada frente a potencia predicha por el Random Forest sobre el conjunto de prueba.	87
A.8	Comparación entre la curva original (gris) y la suavizada con <code>smooth.pos</code> para tres días representativos de la curva de potencia: alta producción (rojo), producción media (naranja) y baja producción (azul).	88
A.9	Curvas de potencia agrupadas por cuartil del score de la FPC1.	89
A.10	Curvas de temperatura agrupadas por cuartil del score de la FPC1.	90
A.11	Curvas GCV frente al número de bases K para las cuatro variables meteorológicas. Línea roja: $K_{\min}$ (mínimo exacto del GCV). Línea verde: K_{ISE} seleccionado por la regla de un error estándar. Línea naranja: umbral $\widehat{\text{GCV}}(K_{\min}) + \widehat{\text{SE}}$.	91
A.12	Funciones parámetro estimadas $\hat{\beta}(t)$ del modelo M4 para las covariables de radiación, temperatura, humedad relativa, velocidad del viento y presión atmosférica.	91
A.13	Diagnóstico de residuos del modelo final M3: valores ajustados frente a observados (izquierda), residuos frente a valores ajustados (centro) y QQ-plot de los residuos (derecha).	92

Índice de tablas

3.1	Resumen de los costes estimados del proyecto.	29
4.1	Volumen de registros asíncronos capturados por el sistema SCADA.	31
4.2	Variables meteorológicas extraídas de la estación CIS Ferrol.	33
4.3	Estadísticas descriptivas de las variables diarias.	36
5.1	Varianza explicada por las componentes principales del PCA sobre los tres inversores.	45
5.2	<i>Loadings</i> de las componentes principales del PCA sobre los tres inversores. . .	46
5.3	Varianza explicada por las componentes principales del PCA sobre todas las variables.	46
5.4	<i>Loadings</i> de las dos componentes principales retenidas del PCA sobre todas las variables.	47
5.5	Tabla de contingencia entre el <i>clustering</i> A (meteorología y potencia) y el <i>clustering</i> B (solo potencia). La mayor dispersión en el <i>cluster 2</i> refleja que los días de producción media son los más sensibles a la inclusión o exclusión de variables meteorológicas.	54
5.6	Métricas de validación cruzada (5-CV, 10 repeticiones).	59
5.7	Comparativa de métricas en el conjunto de prueba.	60
6.1	Resumen de los objetos <code>fdata</code> que componen el <code>ldata_fv</code>	62
6.2	Porcentaje de varianza explicada por componente para las seis variables funcionales.	69

7.1	Comparación de todos los modelos sobre conjunto de entrenamiento y de prueba. M0 es el modelo escalar seleccionado del Capítulo 5; M3 es el modelo funcional seleccionado como modelo final. Las métricas de M0 y RF corresponden a su reevaluación sobre el conjunto de prueba común de 85 días, por lo que difieren ligeramente de las reportadas en el Capítulo 5.	78
A.1	Registros asíncronos del SCADA correspondientes al 10 de marzo de 2025. . .	83
A.3	Autovalores de la matriz de productos escalares centrados y bondad de ajuste acumulada para cada dimensión (MDS sobre variables).	84
A.4	Coeficientes estimados del modelo de regresión lineal múltiple seleccionado. Todos los predictores son significativos al nivel del 5 %.	85
A.5	Coeficientes estimados del modelo RLM seleccionado excluyendo las 16 observaciones con distancia de Cook superior a $4/n$. Nótese que <code>MES_sin</code> pierde la significación individual al 5 % respecto al modelo original.	86
A.6	Número de bases B-spline seleccionadas por el criterio GCV ($K_{\min}$) y por la regla de un error estándar (K_{1SE}). El ratio se calcula como K_{1SE} dividido entre el número de puntos de discretización (144).	88
A.7	Distribución de las 432 curvas diarias de potencia por estación meteorológica, sobre el conjunto de datos completo previo a la detección de outliers.	89
A.8	Outliers funcionales confirmados por el análisis estratificado. La profundidad FM se calcula dentro del grupo estacional correspondiente.	90

Introducción

El presente Trabajo de Fin de Grado se enmarca dentro de la estrategia de transformación digital y eficiencia energética de Navantia. En este capítulo se detalla el contexto que motiva el proyecto, se definen los objetivos principales y específicos, y se presenta la estructura que seguirá la memoria.

1.1 Contexto y motivación

El astillero de Navantia en la ría de Ferrol es uno de los complejos de construcción y reparación naval más importantes de España, con una actividad que conlleva un coste energético muy elevado: la factoría dispone de una subestación propia de 132 kV con capacidad de transformación de 30 MVA para atender su demanda [1], y las primeras instalaciones de autoconsumo fotovoltaico, a pesar de sumar más de 1 300 kWp, apenas cubren el 10 % del consumo eléctrico de la planta [2]. Además de ser una decisión estratégica de la empresa, reducir esa huella energética es también una respuesta a exigencias que llegan desde distintos niveles, desde el autonómico hasta el europeo.

En Galicia, la transición energética avanza, pero con dificultades. La comunidad cuenta con cerca de 11 000 MW de capacidad renovable instalada, lo que la convierte en uno de los principales productores de electricidad verde de España [3]. Sin embargo, su tejido industrial sigue siendo muy dependiente de los combustibles fósiles: en 2024, los productos petrolíferos y el gas suponían todavía el 61 % del consumo energético final gallego [4]. Para revertir esta tendencia, la Xunta aprobó en 2022 la Agenda Energética de Galicia 2030 (AxEGa30), que fija como objetivo alcanzar el 58 % de renovables en el consumo energético final y la neutralidad climática en 2050 [5]. En ese marco, el autoconsumo industrial ocupa un lugar destacado como herramienta de descarbonización para empresas con alta demanda eléctrica.

A nivel nacional, el Plan Nacional Integrado de Energía y Clima (PNIEC 2023-2030), aprobado por el Consejo de Ministros en septiembre de 2024, eleva las metas y las convierte en objetivos vinculantes. Entre ellos destaca la instalación de 76 GW de capacidad fotovoltaica en 2030, de los cuales 19 GW corresponden específicamente al autoconsumo, lo que convierte esta modalidad en una palanca estratégica para la descarbonización del tejido industrial [6].

El contexto europeo plantea un escenario todavía más exigente. El Pacto Verde Europeo, aprobado por la Comisión Europea, tiene como meta principal alcanzar la neutralidad climática en 2050 [7]. El paquete legislativo “*Objetivo 55*” traduce esa ambición en obligación jurídica: reducir las emisiones de gases de efecto invernadero en al menos un 55 % para 2030 respecto a los niveles de 1990. Para los sectores sujetos al Régimen de Comercio de Derechos de Emisión de la UE (RCDE UE), entre los que se encuentra la industria pesada, la exigencia es aún mayor: el objetivo sectorial asciende al 62 % de reducción respecto a 2005 [8].

Ante este panorama tan exigente, Navantia se ha comprometido a alcanzar la neutralidad de carbono en 2040 [9]. Uno de los ejes fundamentales de ese plan es la instalación progresiva de sistemas de autoconsumo fotovoltaico en las cubiertas de su factoría. Las dos primeras instalaciones, financiadas con fondos europeos *Next Generation* en el marco del PERTE del sector naval, se ubican en los talleres de prearmamento II (388,80 kWp) y de módulos y reparaciones (284,34 kWp) [2], mostrado en la Figura 1.1. A estas se suma la instalación de los almacenes del muelle 9, adjudicada en febrero de 2025 con una potencia de 672,84 kWp [10], y una cuarta instalación de 1 296 kWp sobre la cubierta de la Fábrica Digital de Bloques, licitada en mayo de 2026 para alcanzar los 6 MW de generación renovable en la factoría [11].



Figura 1.1: Paneles fotovoltaicos instalados sobre las cubiertas del taller de módulos y reparaciones. [Fuente: [Navantia](#)]

La progresiva incorporación de estas instalaciones genera, sin embargo, una nueva capa de complejidad en la gestión energética del astillero. Los datos de producción de cada planta se recogen a través del sistema SCADA¹ de la factoría (véase Figura 1.2), concebido para la monitorización operativa, no para generar predicciones fiables ni para extrapolar el conocimiento extraído a las nuevas plantas. Sin modelos predictivos robustos, la planificación de las operaciones del astillero, la optimización de la gestión energética y la detección temprana de anomalías quedan sujetas a la intuición en lugar de a evidencia cuantitativa [12].




Figura 1.2: Vista aérea del astillero de Navantia en Ferrol desde el sistema SCADA de la factoría, con la localización de las instalaciones fotovoltaicas señalizada mediante iconos sobre las cubiertas correspondientes.

El presente trabajo aborda precisamente esa brecha. A partir de los datos históricos del taller de módulos y reparaciones (primera instalación con más de un año de operación) se desarrolla un flujo analítico que, partiendo del preprocesamiento de las series brutas, llega hasta la construcción de modelos predictivos con capacidad de transferirse a las nuevas plantas a medida que acumulen suficiente historial de datos.

1.2 Objetivos del TFG

Para dar respuesta al problema descrito en la sección anterior, los objetivos de este trabajo se articulan en torno a un flujo que avanza desde el tratamiento de los datos brutos hasta la construcción y comparación de modelos predictivos.

¹ SCADA (*Supervisory Control and Data Acquisition*) es un sistema de software y hardware que permite a las industrias supervisar, controlar y automatizar procesos a nivel local o remoto.

1.2.1 Objetivo principal

El propósito de este TFG es analizar y modelizar la producción fotovoltaica en un entorno industrial a partir de variables meteorológicas. Para ello, se plantea el desarrollo de un flujo de trabajo que abarca desde el tratamiento de series temporales con irregularidades, hasta la aplicación de técnicas de análisis multivariante y análisis de datos funcionales (FDA), con el fin de identificar patrones de funcionamiento, detectar posibles anomalías y desarrollar modelos de predicción.

1.2.2 Objetivos secundarios

Para alcanzar el objetivo principal, se establecen los siguientes objetivos secundarios:

- **Preprocesamiento de datos:** Construir un conjunto de datos unificado, consistente y de calidad a partir de las fuentes heterogéneas del sistema SCADA y la API de MeteoGalicia, resolviendo los problemas de asincronía y desfase horario propios de cada fuente, y generando las representaciones temporales necesarias para los análisis posteriores.
- **Detección de anomalías:** Identificar días y curvas de producción con comportamiento atípico mediante un enfoque que combina la detección multivariante basada en densidad local y técnicas de profundidad funcional sobre las curvas diarias de producción, distinguiendo en todo momento entre anomalías de origen técnico y variabilidad climática real.
- **Reducción de la dimensión y visualización:** Reducir la dimensionalidad del conjunto de variables del estudio y obtener representaciones en espacios de baja dimensión que permitan, por un lado, explorar visualmente las tipologías de días y la variabilidad del sistema y, por otro, estudiar las relaciones de similitud entre variables. Para ello se aplican análisis de componentes principales (PCA) y escalamiento multidimensional clásico (MDS).
- **Segmentación de perfiles operativos:** Identificar agrupaciones naturales de días con comportamiento homogéneo mediante técnicas de *clustering*, comparando tres enfoques según el conjunto de variables considerado (meteorológicas, productivas y conjuntas), con el fin de caracterizar los distintos regímenes operativos de la instalación a lo largo del período de estudio.
- **Representación funcional:** Construir el objeto funcional de la instalación a partir de las curvas diarias de potencia y variables meteorológicas, aplicar suavizado y llevar a cabo un análisis de componentes principales funcional (FPCA) para identificar los modos de variación dominantes de la generación fotovoltaica a lo largo del año.

- **Modelado y comparación de enfoques predictivos:** Construir y comparar modelos de regresión clásica y modelos de regresión funcional para la predicción de la potencia generada. La comparación entre ambos enfoques se realizará mediante métricas estándar de error (RMSE, R^2) y esquemas de validación cruzada.

1.3 Estructura de la memoria

El presente documento se estructura en siete capítulos principales, diseñados para guiar al lector desde la contextualización inicial del problema industrial hasta la obtención y evaluación de los resultados analíticos:

- **Capítulo 1. Introducción:** Expone el marco normativo europeo y nacional que impulsa la transición energética en la industria, así como el contexto corporativo de Navantia y su apuesta por el autoconsumo fotovoltaico en la ría de Ferrol. A partir de ese contexto se definen el objetivo general y los objetivos específicos que guían el trabajo, y se detalla la estructura del documento.
- **Capítulo 2. Marco teórico:** Presenta los fundamentos de las instalaciones fotovoltaicas y del sistema SCADA que registra su producción. A continuación desarrolla la teoría estadística en la que se apoya el estudio, abarcando tanto las técnicas de análisis multivariante como las del análisis de datos funcionales.
- **Capítulo 3. Metodología y planificación:** Describe la metodología de ciencia de datos seguida a lo largo del proyecto y la planificación temporal de sus distintas fases. Asimismo, detalla las herramientas software empleadas y realiza una estimación de los costes económicos asociados al desarrollo del trabajo.
- **Capítulo 4. Datos y análisis exploratorio:** Describe el origen y características de la información analizada: especificaciones técnicas de la instalación fotovoltaica de Navantia, variables y procedencia de los registros. Posteriormente, se realiza un análisis estadístico exhaustivo que abarca desde la caracterización individual de las variables hasta el estudio de sus interdependencias, sentando las bases para el posterior modelado predictivo.
- **Capítulo 5. Análisis multivariante:** Aborda el comportamiento conjunto del sistema mediante técnicas de análisis multivariante. Tras la detección y tratamiento de valores atípicos univariantes y multivariantes, se aplica PCA para obtener una representación reducida de las variables del sistema. El MDS permite explorar visualmente las relaciones de similitud entre variables. A continuación, se segmentan los días mediante cluste-

ring k -means para identificar patrones de producción. Finalmente, se ajustan modelos de regresión para la predicción de la potencia media diaria.

- **Capítulo 6. Análisis funcional:** Trata cada día como una curva continua observada en una rejilla de diez minutos. Se construyen y suavizan los objetos funcionales, se detectan días atípicos mediante profundidad de Fraiman-Muniz (FM), se aplica FPCA para extraer los principales modos de variación, y se desarrollan modelos de regresión funcional que predicen la potencia media diaria a partir de predictores funcionales como la radiación o la temperatura.
- **Capítulo 7. Conclusiones y trabajo futuro:** Recapitula los principales resultados obtenidos en ambos enfoques, sintetiza las lecciones metodológicas extraídas, relaciona el trabajo con las competencias de la titulación y propone las líneas en las que el estudio admite continuación.

Capítulo 2

Marco teórico

Este capítulo recoge los fundamentos teóricos sobre los que se apoya el trabajo. En primer lugar, se introducen los principios básicos de la generación solar fotovoltaica. A continuación, se presentan las técnicas de análisis multivariante aplicadas sobre datos diarios agregados. Por último, se expone el marco del análisis de datos funcionales, paradigma que permite tratar cada perfil de producción diezminutal como una curva continua.

2.1 Conceptos fundamentales de energía fotovoltaica

La energía solar fotovoltaica es una fuente de generación eléctrica renovable, inagotable y libre de emisiones contaminantes, que se obtiene al convertir directamente la luz del sol en electricidad mediante el efecto fotovoltaico. Considerada hoy en día uno de los pilares fundamentales para alcanzar la neutralidad climática, esta tecnología presenta como ventaja adicional que la generación se produce de forma silenciosa y sin partes móviles [13, 14]. No obstante, la electricidad generada en corriente continua (CC) debe ser transformada a corriente alterna (CA) antes de poder inyectarse en la red. Para comprender la naturaleza de los datos y los patrones de producción que se analizan en capítulos posteriores, resulta fundamental describir los componentes principales de una instalación fotovoltaica.

2.1.1 Panel fotovoltaico

Constituye el primer eslabón en la cadena de generación. Es el dispositivo encargado de captar la irradiancia incidente y transformarla directamente en energía eléctrica en forma de CC [13]. Entre las tecnologías disponibles, destacan las células de silicio cristalino¹, que pese a un mayor coste de fabricación, ofrecen un rendimiento superior bajo determinadas condiciones de irradiancia.

¹ Sus propiedades semiconductoras lo convierten en el material base de la industria electrónica y fotovoltaica. El silicio cristalino (c-Si) hace referencia a su forma sólida con una estructura cristalina ordenada.

2.1.2 Inversor

Constituye el núcleo operativo del sistema y el elemento central de este estudio. El inversor realiza la conversión de CC a CA, ajustando la tensión y la frecuencia a los estándares de la red. Más allá de esta función de conversión energética, actúa como el principal mecanismo de seguridad y control de la instalación: protege el sistema frente a sobrecargas, cortocircuitos y fluctuaciones anómalas de voltaje, garantizando tanto la durabilidad de los paneles como la estabilidad de la red eléctrica industrial [15].

2.1.3 Monitorización SCADA

En instalaciones fotovoltaicas y entornos industriales de gran escala, la monitorización y el control se realizan a través de sistemas SCADA (*Supervisory Control and Data Acquisition*). Específicamente, la monitorización de estas plantas fotovoltaicas se lleva a cabo bajo la plataforma WinCC OA (Open Architecture) de Siemens. Este sistema constituye el pilar fundamental para la adquisición de datos en tiempo real, ya que registra todos los parámetros y elementos de la instalación del taller de reparaciones y el taller de módulos.

2.2 Estado del arte

La monitorización y el mantenimiento predictivo de instalaciones fotovoltaicas han experimentado una evolución significativa en los últimos años, impulsados por la disponibilidad de datos masivos y el desarrollo de algoritmos de aprendizaje automático. Diversos estudios han demostrado la eficacia del *Machine Learning* clásico para la detección de anomalías. Por ejemplo, enfoques recientes han evaluado algoritmos como XGBoost y Random Forest logrando precisiones superiores al 99 % en la clasificación de múltiples fallos, incluyendo cortocircuitos y sombreados [16]. Asimismo, la aplicación de modelos de regresión ha permitido analizar de forma precisa el impacto directo que los circuitos abiertos y los sombreados parciales tienen sobre la potencia de salida [17].

No obstante, la robustez de cualquier modelo predictivo en este ámbito está intrínsecamente ligada a las condiciones atmosféricas. Estudios sobre la interdependencia climática [18] han demostrado que la inclusión y el filtrado adecuado de variables como la temperatura, la humedad y la nubosidad son críticos para establecer un *baseline* de producción fiable.

La naturaleza continua de la generación de energía solar a lo largo del día hace que el análisis de datos funcionales sea un enfoque mucho más natural para este dominio. En lugar de tratar los datos como puntos discretos asíncronos, el FDA permite modelar la producción diaria como curvas continuas [19]. En este contexto, herramientas como el paquete `fda.usc` para R [20] se han consolidado como el estándar para el suavizado y tratamiento de estas señales. Trabajos como el de Sosa Donoso et al. [21] han extendido algoritmos como el *Local*

Correlation Integral (LOCI) al dominio funcional, permitiendo detectar *outliers* basándose no solo en caídas abruptas de magnitud (e.g., el apagado de un inversor), sino en alteraciones anómalas en la forma de la curva a lo largo del día.

Finalmente, este proyecto toma como punto de partida el TFG de Marina Sánchez Allegue [22], quien empleó el análisis de datos funcionales en un entorno académico. El presente trabajo evoluciona dicho enfoque hacia el ámbito industrial de Navantia Ferrol, diferenciándose en tres pilares: la complejidad del entorno, la integración de una fase multivariante exhaustiva y la resolución de retos como la sincronización de datos o la detección de anomalías operativas.

2.3 Análisis multivariante

El análisis multivariante comprende el conjunto de técnicas estadísticas orientadas al estudio y modelado simultáneo de múltiples variables sobre un mismo conjunto de observaciones. Esta sección establece el marco metodológico del Capítulo 5, recorriendo la cuantificación de asociaciones lineales y no lineales, la detección de anomalías multivariantes, la reducción de dimensionalidad, el agrupamiento no supervisado y la modelización de la variable de respuesta a través de modelos de regresión.

2.3.1 Correlación

La correlación es una medida estadística que expresa la fuerza y dirección de la relación entre dos variables. Aunque existen métodos para cuantificar la asociación entre variables cualitativas (por ejemplo, el test chi-cuadrado), en este trabajo nos centramos en la correlación entre variables continuas. Para este tipo de variables, los métodos más utilizados son el coeficiente de correlación lineal de Pearson, que mide la relación lineal, y la correlación de distancias de Székely, que detecta cualquier tipo de dependencia estadística [23].

El coeficiente de correlación lineal de Pearson entre dos variables X e Y se define como:

$$r_{XY} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}} \quad (2.1)$$

donde $\bar{x}$ y $\bar{y}$ son las medias de X e Y respectivamente, x_i e y_i representan cada observación de dichas variables y n el tamaño muestral. Este coeficiente toma valores en el intervalo $\in [-1, 1]$. Es importante destacar que la existencia de correlación no implica necesariamente causalidad [24].

Para complementar el análisis de Pearson, se ha implementado la correlación de distancias de Székely, introducida inicialmente por Gábor J. Székely en 2005 y formalizada junto a Rizzo y Bakirov [25]. A diferencia del coeficiente de Pearson, que puede resultar nulo incluso cuando existe una relación dependiente pero no lineal entre las variables, la correlación de distancias

surge como una medida estadística más general y versátil. La propiedad más importante de la correlación de distancias es que su valor es exactamente cero si, y solo si, los vectores aleatorios son estadísticamente independientes. Dadas dos variables X e Y , esta equivalencia se expresa como [25]:

$$\mathcal{R}(X, Y) = 0 \iff X \text{ e } Y \text{ son independientes} \quad (2.2)$$

La correlación de distancias produce un coeficiente acotado en el intervalo $[0, 1]$. En esta escala, un valor de 0 indica independencia total, mientras que un valor cercano a 1 implica una fuerte dependencia, independientemente de la forma geométrica que adopte dicha relación.

Matemáticamente, el coeficiente de correlación de distancias empírico $\mathcal{R}_n(X, Y)$ para dos muestras de tamaño n se define como:

$$\mathcal{R}_n(X, Y) = \begin{cases} \frac{\mathcal{V}_n(X, Y)}{\sqrt{\mathcal{V}_n(X, X) \cdot \mathcal{V}_n(Y, Y)}} & \text{si } \mathcal{V}_n(X, X) \mathcal{V}_n(Y, Y) > 0 \\ 0 & \text{en caso contrario} \end{cases} \quad (2.3)$$

donde $\mathcal{V}_n(X, Y)$ representa la covarianza empírica de distancias entre las muestras de X e Y , construida a partir de las matrices de dobles distancias centradas.

2.3.2 Detección de outliers: local outlier factor (LOF)

El algoritmo *local outlier factor* (LOF) es un método no supervisado de detección de datos atípicos basado en la densidad. Su objetivo principal es identificar puntos de datos anómalos calculando la desviación de la densidad local de un punto dado con respecto a sus vecinos. El cálculo del LOF se establece a través de los siguientes conceptos [26]:

1. **Distancia de alcanzabilidad:** Se calcula como el máximo entre la k -distancia del vecino de un punto B y la distancia geométrica real entre el punto A y el punto B . Esto provoca que todos los objetos dentro del núcleo cercano se consideren igualmente distantes, lo que sirve para reducir las fluctuaciones estadísticas de las medidas.
2. **Densidad de alcanzabilidad local:** Es la inversa de la distancia promedio de alcanzabilidad de los k vecinos más cercanos de un punto. En términos prácticos, si esta medida de distancia promedio es muy grande, significa que los vecinos están muy alejados y existe una baja densidad local alrededor de dicho punto.
3. **Cálculo del factor LOF:** Es el cociente entre el promedio de las densidades de alcanzabilidad locales de los vecinos de un punto y la densidad de alcanzabilidad local de ese mismo punto.

La puntuación LOF se interpreta según el siguiente criterio [26]:

- **LOF ≈ 1 :** Indica que el objeto tiene una densidad local muy similar a la de sus vecinos y, por lo tanto, no es un valor atípico.
- **LOF < 1 :** Indica una densidad mayor que la de los vecinos, considerándose un valor típico o normal.
- **LOF > 1 :** Sugiere que el punto se encuentra en una región significativamente más dispersa que sus vecinos, lo que evidencia un valor atípico. En la práctica, como regla empírica, a menudo se consideran anómalos los registros con valores de LOF por encima de 1,5 o 2, dependiendo de la naturaleza del problema y del parámetro k seleccionado.

2.3.3 Análisis de componentes principales (PCA)

El análisis de componentes principales (PCA, por sus siglas en inglés) es una técnica de reducción de dimensionalidad de un conjunto de datos que contiene un gran número de variables interrelacionadas [27]. Su objetivo es condensar la información de p variables originales en un número menor de dimensiones q , minimizando la pérdida de información y facilitando la interpretación visual de los datos.

Desde una perspectiva geométrica, el PCA busca hallar direcciones ortogonales (y, por tanto, linealmente independientes) en el espacio de las variables sobre las que la proyección de los datos maximice la varianza [23]. En una primera etapa, el procedimiento encuentra la combinación lineal unitaria de las variables originales que captura la mayor varianza posible, denominada primera componente principal. A continuación, se busca una segunda dirección ortogonal (incorrelada con la primera) que recoja la máxima varianza residual, repitiendo este proceso de manera iterativa hasta extraer componentes que agoten el espacio original [23]. La base matemática para determinar estas direcciones recae en la diagonalización ortogonal de la matriz de varianzas-covarianzas, Σ (o la matriz de correlaciones, P , de las variables originales).

Para determinar el número óptimo de componentes a retener, se analiza la proporción de varianza explicada acumulada:

$$\text{Varianza acumulada} = \frac{\sum_{i=1}^q \lambda_i}{\sum_{i=1}^p \lambda_i} \quad (2.4)$$

donde λ_i es el autovalor asociado a la componente principal i -ésima, que representa la varianza explicada por dicha componente.

Un criterio frecuentemente utilizado consiste en retener el número mínimo de componentes principales que expliquen el 70–90 % de la variabilidad total, aunque este umbral puede variar según el contexto y los objetivos del análisis. Otro criterio utilizado es la regla de Kaiser, que recomienda retener las componentes con autovalor asociado superior a la unidad [27].

Finalmente, la interpretación del modelo se apoya en dos conceptos fundamentales [28]:

- **Scores (puntuaciones):** Coordenadas de las observaciones en el nuevo espacio. Si se representan en un espacio de dimensión reducida, permiten visualizar posibles similitudes entre individuos.
- **Loadings (cargas):** Coeficientes que indican la correlación entre las variables originales y las componentes. Valores altos en algún coeficiente permiten asignar un significado semántico a cada eje.

2.3.4 Escalamiento multidimensional (MDS)

El escalamiento multidimensional (MDS, por sus siglas en inglés) es una técnica de análisis multivariante que, partiendo de una matriz de distancias o similitudes entre individuos, produce una representación de los individuos en un espacio euclídeo de dimensión reducida de modo que las distancias en dicha representación aproximen lo mejor posible a las distancias de partida [29].

Dentro de la familia de métodos MDS es habitual distinguir entre dos grandes variantes. Los métodos no métricos utilizan únicamente los rangos de las distancias que conforman el triángulo supradiagonal de la matriz de distancias D , es decir, el orden relativo de las disimilitudes, pero no sus valores numéricos concretos. Los métodos métricos, por su parte, tratan de obtener las coordenadas de los puntos a partir de los propios valores de las distancias, no solo de su rango [23]. En el presente trabajo se emplea exclusivamente un método métrico: la denominada solución clásica al problema del MDS.

Algoritmo de la solución clásica

Dada una matriz de distancias D , el procedimiento consiste en [28]:

1. Construir la matriz $A = (a_{ij})$, con $a_{ij} = -\frac{1}{2}d_{ij}^2$.
2. Obtener la matriz de productos escalares centrados $B = HAH$, donde $H = I_n - \frac{1}{n}1_n1_n^\top$ es la matriz de doble centrado.
3. Extraer los k mayores autovalores positivos $\lambda_1, \dots, \lambda_k$ de B y sus respectivos autovectores normalizados $x^{(i)}$, tales que $x^{(i)\top}x^{(i)} = \lambda_i$.
4. Determinar las coordenadas resultantes mediante $X = \Gamma_k \Lambda_k^{1/2}$, donde Γ_k son los autovectores y Λ_k la matriz diagonal de autovalores.

MDS a partir de matrices de similitud

Un caso de especial relevancia en el análisis multivariante es el uso del coeficiente de correlación de Pearson como medida de similitud entre variables. La transformación estándar de similitud a distancia se particulariza entonces como [29]:

$$d(i, j) = \sqrt{2(1 - r_{ij})}, \quad (2.5)$$

donde r_{ij} denota la correlación de Pearson entre las variables i -ésima y j -ésima del conjunto de datos.

Autovalores y elección de la dimensión

La elección de la dimensión k se realiza reteniendo las k primeras dimensiones asociadas a los autovalores positivos más grandes de B . La proporción de estructura recogida se cuantifica mediante la bondad de ajuste (*Goodness of Fit*, GOF) [29]:

$$\text{GOF}(k) = \frac{\sum_{i=1}^k \lambda_i}{\sum_{i: \lambda_i > 0} \lambda_i}. \quad (2.6)$$

2.3.5 Clasificación no supervisada: *clustering*

El análisis *cluster*, también conocido como clasificación no supervisada, es un conjunto de técnicas estadísticas multivariantes cuyo objetivo principal es resolver el siguiente problema: dado un conjunto de individuos caracterizados por la información de múltiples variables, el reto es organizarlos de manera que los elementos pertenecientes a un mismo grupo (*cluster*) sean lo más similares y homogéneos posible entre sí, asegurando al mismo tiempo que los diferentes grupos sean lo más disimilares o divergentes posibles entre ellos [23].

La diferencia fundamental con otras técnicas de clasificación (como el análisis discriminante o clasificación supervisada) es que no utiliza categorías preexistentes, sino que busca descubrir la estructura de los grupos directamente a partir de los datos [23].

Tipología de métodos

La clasificación más común del análisis *cluster* es la siguiente [23]:

- **Métodos jerárquicos:** No crean una partición única, sino toda una jerarquía de grupos anidados que se van fusionando o subdividiendo sucesivamente. La homogeneidad de-

crece conforme los grupos se hacen más amplios, y el proceso completo se representa visualmente mediante un árbol invertido llamado dendrograma.

- **Métodos no jerárquicos:** Se forman grupos homogéneos de manera disjunta sin establecer relaciones jerárquicas entre ellos. Generalmente, requieren que la persona usuaria fije de antemano el número de grupos (k) que desea buscar (como ocurre en el algoritmo de las k -means) y se basan en encontrar un óptimo local.

En este trabajo se consideró el algoritmo k -means como método de clustering no jerárquico. Esta elección se fundamenta en el objetivo del análisis: identificar grupos bien diferenciados de días según sus características meteorológicas y productivas, sin necesidad de establecer relaciones jerárquicas entre ellos, permitiendo además evaluar de forma directa la calidad de la agrupación mediante el análisis de la varianza intra e inter-cluster.

Algoritmo k -means

El k -means es un algoritmo de clasificación no supervisada que busca dividir un conjunto de n individuos en k grupos disjuntos minimizando la suma de distancias de cada punto al centroide de su grupo [30]. Denotando por $(\vec{X}_1, \dots, \vec{X}_n)$ la muestra observada y por $\vec{C}_1, \dots, \vec{C}_k$ los centroides o medias de los k grupos buscados, se trata de elegir dichos centroides de forma que se minimice la función

$$g(\vec{C}_1, \dots, \vec{C}_k) = \sum_{i=1}^n \min_{j=1, \dots, k} d(\vec{X}_i, \vec{C}_j), \quad (2.7)$$

siendo d cierta distancia, como por ejemplo la euclídea o la de Mahalanobis.

La elección de dicha medida de distancia no es trivial: los resultados del análisis clúster pueden variar sustancialmente en función de la distancia empleada. Habiendo normalizado previamente las variables, en este proyecto se opta por la distancia euclídea, definida como:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} \quad (2.8)$$

Variante algorítmica: MacQueen

En el presente estudio se ha optado por la variante de MacQueen [30] para la implementación del algoritmo k -means. A diferencia del algoritmo tradicional de Lloyd, que recalcula los centroides únicamente al finalizar cada iteración completa sobre el conjunto de datos [31], la estrategia de MacQueen realiza actualizaciones progresivas de los centroides cada vez que un objeto es asignado a un nuevo grupo [30]. Esta actualización continua favorece una con-

vergencia más rápida al reducir el número de iteraciones necesarias y dota al proceso de una mayor estabilidad, mitigando el impacto de inicializaciones desfavorables.

2.3.6 Modelos de regresión

Los modelos de regresión proporcionan un marco estadístico para cuantificar la relación entre una variable respuesta y un conjunto de covariables, y para predecir el valor de la respuesta ante nuevas observaciones [32, 33]. Se exploran dos enfoques: un modelo paramétrico clásico basado en la regresión lineal múltiple, y un modelo no lineal (Random Forest), que permite capturar dependencias complejas entre los predictores sin imponer una forma funcional a priori.

Regresión lineal múltiple

Sea Y la respuesta y $X_1, \dots, X_k$ un conjunto de k variables explicativas o regresoras. Dada una muestra de n observaciones $\{(X_{i1}, \dots, X_{ik}, Y_i)\}_{i=1}^n$, el modelo asume que la respuesta se relaciona linealmente con las covariables a través de la expresión [33]:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_k X_{ik} + \varepsilon_i, \quad \varepsilon_i \text{ i.i.d. } \mathcal{N}(0, \sigma^2), \quad i = 1, \dots, n, \quad (2.9)$$

donde $\beta_0, \beta_1, \dots, \beta_k$ son los coeficientes poblacionales desconocidos y ε_i el error aleatorio, que recoge la parte de Y_i no explicada por las covariables.

Estimación por mínimos cuadrados ordinarios (MCO). Los coeficientes se estiman minimizando la suma de cuadrados de los residuos $\sum_{i=1}^n (Y_i - \hat{Y}_i)^2$. Bajo las hipótesis del modelo (2.9), la solución cerrada para el vector de coeficientes es [32]:

$$\hat{\beta} = (X^\top X)^{-1} X^\top Y. \quad (2.10)$$

A partir de estos estimadores, se define la estimación de la variable respuesta (o valores ajustados) como $\hat{Y} = X\hat{\beta}$, donde cada componente $\hat{Y}_i$ representa el valor predicho por el modelo para la i -ésima observación. El teorema de Gauss-Markov garantiza que $\hat{\beta}$ es el estimador lineal insesgado de mínima varianza (BLUE). Por su parte, la varianza del error se estima mediante $\hat{\sigma}^2 = \text{SS(R)}/(n - k - 1)$, donde SS(R) es la suma de cuadrados residual.

Bondad del ajuste. La calidad global del modelo se evalúa mediante el coeficiente de determinación R^2 , que representa la proporción de variabilidad de Y explicada por las covariables.

Dado que R^2 crece al añadir regresoras, se utiliza su versión ajustada, que penaliza la complejidad [33]:

$$R_{\text{adj}}^2 = 1 - \frac{n-1}{n-k-1}(1-R^2). \quad (2.11)$$

Se complementa con el contraste F global ($H_0 : \beta_1 = \dots = \beta_k = 0$) y los contrastes individuales sobre cada β_j mediante el estadístico t . Para variables categóricas con más de dos niveles se utiliza la suma de cuadrados de tipo II del análisis de la varianza, que proporciona el efecto neto de cada variable controlando por las restantes [32].

Multicolinealidad. Cuando dos o más regresoras presentan correlación lineal elevada, $X^\top X$ se aproxima a la singularidad y los estimadores $\hat{\beta}_j$ se vuelven inestables, con varianzas infladas y signos a veces contraintuitivos [32, 33]. Este fenómeno, denominado multicolinealidad, no afecta a la bondad global del ajuste (R^2 permanece alto) ni a la capacidad predictiva del modelo sobre observaciones similares a las muestrales, pero sí compromete gravemente la inferencia sobre los coeficientes individuales y la interpretabilidad del modelo [34, 35].

Para diagnosticar el problema se emplean las siguientes herramientas:

- **Factor de Inflación de la Varianza (FIV).** Para la covariable X_j se define como [35]:

$$\text{FIV}_j = \frac{1}{1 - R_{(j)}^2}, \quad j = 1, \dots, k, \quad (2.12)$$

donde $R_{(j)}^2$ es el coeficiente de determinación de la regresión marginal de X_j sobre el resto de regresoras. El FIV mide el factor de incremento en la varianza de $\hat{\beta}_j$ respecto a la varianza que tendría si X_j fuera ortogonal al resto de covariables. Se considera indicio de multicolinealidad $\text{FIV}_j > 10$, o de forma más estricta comparar FIV_j con $(1 - R^2)^{-1}$ del modelo completo: valores FIV_j superiores a este umbral indican que X_j comparte más información con las demás covariables que con la respuesta [36].

- **Índice de condicionamiento (IC).** A partir de los autovalores $\lambda_1 \geq \dots \geq \lambda_k > 0$ de la matriz de correlaciones R de las covariables, se define [34]:

$$\text{IC} = \sqrt{\frac{\max_{1 \leq j \leq k} \lambda_j}{\min_{1 \leq j \leq k} \lambda_j}} = \sqrt{\frac{\lambda_1}{\lambda_k}}. \quad (2.13)$$

Valores $\text{IC} > 30$ indican multicolinealidad elevada y $10 \leq \text{IC} < 30$ multicolinealidad moderada. Es preferible calcular el IC sobre R en lugar de sobre $X^\top X$ para evitar la influencia de diferencias de escala en las variables explicativas.

Selección de variables y comparación de modelos. Partiendo del modelo completo con todas las covariables disponibles, se busca un submodelo parsimonioso que conserve una bue-

na capacidad explicativa y predictiva. Los criterios de selección habituales son:

- **C_p de Mallows [37].** Compara el error cuadrático medio del submodelo con el del modelo completo. Para un submodelo con p parámetros (incluyendo el intercepto),

$$C_p = \frac{SS(R)_{(p)}}{MSS(R)} - (n - 2p), \quad (2.14)$$

donde $SS(R)_{(p)}$ denota la suma de cuadrados residual del submodelo, $MSS(R) = SS(R)/(n - k - 1)$ es el cuadrado medio residual del modelo completo con $k + 1$ parámetros, y n es el tamaño muestral. Si el submodelo es adecuado, $E[C_p] \approx p$. Se seleccionan submodelos con $C_p \approx p$ y el menor valor posible.

- **Criterio de información de Akaike (AIC) [38]:**

$$AIC = 2p - 2 \ln \mathcal{L}(\hat{\beta}), \quad (2.15)$$

donde $\mathcal{L}(\hat{\beta})$ es la verosimilitud maximizada del modelo con p parámetros. AIC penaliza la complejidad del modelo ($2p$) al tiempo que recompensa un buen ajuste a los datos (término de log-verosimilitud).

- **Criterio de Información Bayesiano (BIC) de Schwarz [39]:**

$$BIC = p \log n - 2 \ln \mathcal{L}(\hat{\beta}), \quad (2.16)$$

donde n es el tamaño muestral. BIC penaliza más severamente la complejidad que AIC (especialmente cuando n es grande, pues $\log n > 2$) y tiende a seleccionar modelos más parsimoniosos.

En los tres casos, valores menores indican mejor modelo. Estos criterios pueden explorarse mediante búsqueda exhaustiva (todos los subconjuntos posibles de regresoras, factible cuando k es moderado) o mediante procedimientos secuenciales: *forward* (se parte del modelo nulo y se añaden variables), *backward* (se parte del completo y se eliminan) y *stepwise* (combina ambos movimientos en cada iteración).

Diagnosis del modelo. La validez de la inferencia depende del cumplimiento de las hipótesis sobre los errores ε_i : linealidad, homocedasticidad, normalidad e independencia. El diagnóstico se apoya tanto en gráficos como en contrastes formales. Existen múltiples tests para evaluar cada hipótesis; entre las opciones más utilizadas se encuentran:

- **Normalidad:** Test de Lilliefors [40]. Evalúa si los residuos siguen una distribución normal cuando μ y σ son desconocidos.

- **Homocedasticidad:** Test de Breusch-Pagan [41]. Comprueba que la varianza de los errores sea constante y no dependa de los niveles de las variables predictoras.
- **Independencia:** Test de rachas [42] sobre el signo de los residuos. Analiza la aleatoriedad en la secuencia para descartar la existencia de autocorrelación o patrones temporales no explicados por el modelo.

Complementariamente, se analiza la influencia de cada observación en el ajuste. La **distancia de Cook** [43] para la i -ésima observación mide el cambio estandarizado en el vector de predicciones cuando dicha observación se elimina:

$$D_i = \frac{(\hat{Y} - \hat{Y}_{(i)})^\top (\hat{Y} - \hat{Y}_{(i)})}{(k + 1) \text{MSS}(\mathbf{R})}. \quad (2.17)$$

Se suelen considerar influyentes las observaciones con $D_i > 4/n$.

Validación del modelo. La capacidad predictiva real del modelo no puede evaluarse sobre la misma muestra empleada para su ajuste, ya que se incurriría en sobreajuste. Por ello se recurre a técnicas de validación:

- **Partición *train/test*.** Se reserva una fracción (típicamente 20–30 %) para evaluación final, que no interviene en el ajuste ni en la selección del modelo.
- **Validación cruzada *k-fold*.** Se divide el conjunto de entrenamiento en k subconjuntos, se ajusta el modelo k veces usando cada vez $k - 1$ como entrenamiento y el restante como evaluación, y se promedian las métricas. Para reducir la varianza de la estimación se repite el procedimiento varias veces (CV repetida).

La métrica de error empleada es la raíz del error cuadrático medio (RMSE, *Root Mean Squared Error*), expresado en las mismas unidades que la variable respuesta y definido como

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2}, \quad (2.18)$$

donde y_i son los valores observados e $\hat{y}_i$ los predichos.

Modelos no lineales: Random Forest

Random Forest es un método de aprendizaje automático basado en la combinación de múltiples árboles de regresión para reducir la alta varianza que caracteriza a un árbol individual [44]. Cada árbol T_b se entrena sobre una remuestra bootstrap $\mathcal{D}_b^*$ del conjunto de entrenamiento, de modo que la predicción final es el promedio de los B árboles,

$$\hat{f}_{\text{RF}}(x) = \frac{1}{B} \sum_{b=1}^B T_b(x). \quad (2.19)$$

Adicionalmente, en cada nodo de cada árbol la búsqueda del mejor corte se restringe a un subconjunto aleatorio de m_{try} variables, elegido sin reemplazo del total de p predictores. Esta aleatorización adicional decorrelaciona los árboles entre sí, lo que reduce la varianza del ensemble más allá de lo que lograría el bagging por sí solo. Por la Ley de los Grandes Números, aumentar B estabiliza el error sin provocar sobreajuste; en la práctica, $B = 500$ árboles suele ser suficiente [45]. El hiperparámetro crítico del método es m_{try} : valores pequeños aumentan la decorrelación entre árboles pero degradan la calidad individual de cada uno; valores grandes producen árboles más precisos pero más correlados. El valor por defecto para regresión es $\lfloor p/3 \rfloor$ [44], aunque en la práctica se recomienda ajustarlo mediante validación cruzada.

El método proporciona además dos herramientas diagnósticas. El error *out-of-bag* (OOB) estima el error de predicción promediando, para cada observación, solo los árboles que no la incluyeron en su bootstrap, sin necesidad de conjunto de validación separado. La reducción media de impureza (MDI) cuantifica la importancia de cada predictor acumulando la reducción de varianza residual producida en todos los nodos donde esa variable fue seleccionada como corte.

2.4 Análisis de datos funcionales

El análisis de datos funcionales (FDA, del inglés *Functional Data Analysis*) trata cada observación no como un vector de valores discretos, sino como una función continua definida sobre un dominio, habitualmente el tiempo. Esta perspectiva resulta especialmente adecuada cuando los datos presentan una estructura intrínsecamente continua, como los perfiles diarios de producción fotovoltaica o de variables meteorológicas. Esta sección establece el marco metodológico del Capítulo 6, recorriendo los fundamentos de la representación funcional.

2.4.1 El dato funcional: concepto y representación

El FDA es una rama de la estadística que trata como unidad de análisis una función completa en lugar de un vector de observaciones discretas. La idea central, formalizada por Ram-

say y Silverman [19], es que los datos provienen de la realización de un proceso estocástico continuo $X(t)$, con $t \in \mathcal{T} \subset \mathbb{R}$, cuya naturaleza funcional conviene preservar para explotar propiedades como la suavidad y la derivabilidad que el enfoque multivariante ignoraría.

Formalmente, un dato funcional es una observación X_i de una variable aleatoria que toma valores en el espacio de Hilbert $L^2(\mathcal{T})$ de funciones de cuadrado integrable:

$$X_i \in L^2(\mathcal{T}) = \left\{ f : \mathcal{T} \rightarrow \mathbb{R} \mid \int_{\mathcal{T}} f(t)^2 dt < \infty \right\}. \quad (2.20)$$

Una muestra funcional es el conjunto $\{X_1, \dots, X_n\}$, donde cada X_i representa una curva completa y constituye la unidad muestral del análisis [46].

2.4.2 Suavizado y representación en bases

Cuando los datos funcionales se observan en una rejilla de discretización finita $\{t_1, \dots, t_p\} \subset \mathcal{T}$, la primera tarea analítica consiste en obtener una representación continua de cada curva que sea matemáticamente tratable [46]. En el FDA esto se consigue aproximando cada función observada X_i mediante una combinación lineal de K elementos de una base de $L^2(\mathcal{T})$:

$$X_i(t) \approx \sum_{k=1}^K c_{ik} \psi_k(t), \quad (2.21)$$

donde $\{\psi_k\}_{k=1}^K$ es la base elegida y $\mathbf{c}_i = (c_{i1}, \dots, c_{iK})^\top$ son los coeficientes de representación [47]. La elección de la base y del número de elementos K determina el equilibrio entre fidelidad al dato observado y suavidad de la curva reconstruida.

Bases B-spline

La base B-spline de orden m (o grado $m-1$) está formada por polinomios a trozos definidos sobre un conjunto de nodos interiores $\tau_1 < \tau_2 < \dots < \tau_L$ en $\mathcal{T} = [a, b]$. Cada elemento de la base es diferente de cero únicamente en un soporte local de m intervalos consecutivos, lo que confiere al sistema buenas propiedades numéricas y eficiencia computacional. Para un conjunto de L nodos interiores, la dimensión de la base resultante es $K = m + L$. Los B-splines cúbicos ($m = 4$) son los más empleados en la práctica por su capacidad para representar curvas suaves con derivadas continuas hasta orden dos [19].

Para variables que deben ser estrictamente positivas, como la potencia generada o la irradiancia solar, se emplea la variante `smooth.pos`, que modela la curva como $X(t) = \exp(W(t))$ y ajusta $W(t)$ mediante B-spline penalizado, garantizando por construcción que $X(t) > 0$ en todo el dominio.

Suavizado con penalización

Cuando los datos presentan ruido de medición, la representación en base puede incorporar una penalización que limite la curvatura de la función estimada. El criterio a minimizar, denominado PENSSE (*Penalized Sum of Squared Errors*), combina la fidelidad al dato con la rugosidad de la curva [19]:

$$\text{PENSSE}(c) = \sum_{j=1}^p (y_j - X(t_j))^2 + \lambda \int_{\mathcal{T}} [X''(t)]^2 dt. \quad (2.22)$$

Los parámetros K y λ controlan conjuntamente el suavizado: K determina la flexibilidad máxima de la representación y λ penaliza la rugosidad. La estrategia concreta se adapta a la naturaleza de cada variable [47], combinando la elección de k y λ según criterios de parsimonia descritos a continuación.

Selección del número de bases: GCV y regla 1-SE

Para las variables meteorológicas, el número óptimo de bases K se determina minimizando la validación cruzada generalizada (GCV) con $\lambda = 0$ [19, 47]:

$$\text{GCV}(K) = \frac{p^{-1} \|y - \hat{y}\|^2}{(1 - p^{-1} \text{tr}(S_K))^2}, \quad (2.23)$$

donde p es el número de puntos de la rejilla y S_K es la matriz de suavizado que cumple $\hat{y} = S_K y$. La GCV aproxima eficientemente la validación cruzada p -veces, sin necesidad de reajustar el modelo para cada punto.

Dado que el mínimo exacto de la GCV tiende a seleccionar más bases de las necesarias, se aplica la regla de un error estándar: se elige el K más pequeño cuyo valor de GCV no supera el mínimo en más de un error estándar estimado sobre la muestra de curvas,

$$K_{1\text{SE}} = \min\{K : \text{GCV}(K) \leq \text{GCV}(K_{\min}) + \widehat{\text{SE}}\}, \quad (2.24)$$

donde $\widehat{\text{SE}}$ es el error estándar del GCV calculado sobre las n curvas de la muestra. Este criterio favorece la parsimonia sin degradar significativamente el ajuste.

2.4.3 Profundidad funcional y outliers

En el análisis multivariante clásico, la detección de atípicos puede abordarse mediante medidas de distancia o reglas basadas en cuantiles univariantes. En el contexto funcional, no existe un orden total natural para las curvas, por lo que las herramientas clásicas de detección de atípicos no se trasladan directamente. El concepto de profundidad funcional resuelve esta

dificultad asignando a cada curva un valor escalar no negativo que refleja su centralidad respecto al conjunto muestral: cuanto mayor es la profundidad, más central es la curva. La curva más profunda actúa como mediana funcional y las menos profundas son las candidatas a ser valores atípicos [47].

Profundidad de Fraiman-Muniz (FMD)

La profundidad de Fraiman-Muniz (FMD) [48] integra a lo largo del dominio una medida de profundidad univariante calculada en cada instante t :

$$\text{FMD}_i = \int_a^b Z_i(t) dt, \quad (2.25)$$

donde $Z_i(t) = 1 - |1/2 - F_{n,t}(\mathcal{X}_i(t))|$ y $F_{n,t}$ es la distribución empírica de la muestra evaluada en el instante t . El valor $Z_i(t)$ mide la centralidad del dato i en la distribución transversal del conjunto de curvas en el punto t : es máximo cuando $\mathcal{X}_i(t)$ coincide con la mediana transversal, y decrece a medida que el valor se aleja hacia los extremos. Esta profundidad puede interpretarse como el grado promedio de centralidad de la curva a lo largo de todo el dominio.

Profundidad modal (MD)

La profundidad modal (MD) [49] mide cuántas curvas de la muestra se encuentran en la vecindad de la curva evaluada:

$$\hat{f}_h(\mathcal{X}_0) = \frac{1}{n} \sum_{i=1}^n K\left(\frac{d(\mathcal{X}_0, \mathcal{X}_i)}{h}\right), \quad (2.26)$$

donde d es la métrica del espacio funcional, K es un núcleo simétrico y h es el parámetro de ventana. La curva más profunda según este criterio es la que presenta mayor concentración de vecinos, lo que la identifica con la moda funcional.

Detección de valores atípicos funcionales mediante bootstrap

Una vez calculadas las profundidades $\{D_i\}_{i=1}^n$, los valores atípicos se identifican como aquellas curvas cuya profundidad cae por debajo de un umbral C . La dificultad reside en fijar C de forma que la tasa de falsos positivos sea controlada. Febrero Bande y Oviedo de la Fuente [47] proponen dos procedimientos basados en bootstrap:

1. **Procedimiento por recorte** (`outliers.depth.trim`): se genera un conjunto recortado eliminando el α % de curvas menos profundas; las muestras bootstrap se extraen de ese conjunto limpio, y C se define como la mediana de los percentiles del 1 % de las distribuciones de profundidad obtenidas en cada réplica.

2. **Procedimiento por ponderación** (`outliers.depth.pond`): las muestras bootstrap se generan con probabilidades proporcionales a las profundidades, de modo que las curvas más atípicas tienen menor peso en la generación de datos artificiales, y C se determina de forma análoga.

2.4.4 Análisis de componentes principales funcional

El análisis de componentes principales funcional (FPCA) es la extensión natural del PCA clásico al espacio $L^2(\mathcal{T})$. Su objetivo es encontrar las direcciones del espacio funcional que concentran la mayor parte de la variabilidad de la muestra $\{X_i\}_{i=1}^n$ [19, 47].

La función de covarianza muestral $\hat{\Sigma}(s, t)$ da lugar a una familia de autofunciones $\{v_k\}$ y autovalores $\lambda_1 \geq \lambda_2 \geq \dots \geq 0$ que satisfacen:

$$\int_{\mathcal{T}} \hat{\Sigma}(s, t) v_k(t) dt = \lambda_k v_k(s), \quad \langle v_k, v_l \rangle = \delta_{kl}. \quad (2.27)$$

Las autofunciones constituyen una base ortonormal de $L^2(\mathcal{T})$ y representan los modos de variación dominantes del conjunto de curvas [19]. Cada curva centrada puede aproximarse mediante las primeras K componentes:

$$X_i(t) - \mu(t) \approx \sum_{k=1}^K \xi_{ik} v_k(t), \quad (2.28)$$

donde los *scores* $\xi_{ik} = \langle X_i - \mu, v_k \rangle$ resumen la contribución de cada curva al k -ésimo modo de variación.

La proporción de varianza total explicada por las primeras K componentes es:

$$\text{FVE}(K) = \frac{\sum_{k=1}^K \lambda_k}{\sum_{k=1}^{\infty} \lambda_k}, \quad (2.29)$$

criterio análogo al del PCA clásico para elegir el número de componentes a retener. La expansión (2.28) es óptima en el sentido de que minimiza el error de aproximación cuadrático medio para una dimensión de base fijada K [19]. Los *scores* $(\xi_{i1}, \dots, \xi_{iK})$ constituyen una representación multivariante de dimensión reducida de cada curva, y serán utilizados directamente como covariables en el modelo de regresión de la sección 2.4.5.

2.4.5 Regresión funcional

Las secciones anteriores han establecido los instrumentos necesarios para representar cada día de operación como un conjunto de curvas funcionales, detectar comportamientos atípicos y caracterizar su variabilidad mediante autofunciones. El objetivo final del análisis

funcional es predecir la potencia media diaria $\bar{P} \in \mathbb{R}$ a partir de esas curvas.

Según la dimensión de la respuesta y de las covariables, se distinguen cuatro familias de modelos de regresión funcional [47]. En este trabajo interesa exclusivamente el caso respuesta escalar – covariable funcional, pues $\bar{P}$ es un escalar mientras que las covariables son curvas definidas sobre el dominio temporal $\mathcal{T}$.

El modelo lineal funcional con respuesta escalar

Dada una muestra de pares $\{y_i, X_i\}_{i=1}^n$, donde $y_i \in \mathbb{R}$ es una respuesta escalar y X_i es una curva observada sobre el dominio $\mathcal{T}$, el modelo de regresión funcional lineal con respuesta escalar relaciona ambas mediante

$$y_i = \alpha + \langle X_i, \beta \rangle + \varepsilon_i, \quad (2.30)$$

donde $\langle \cdot, \cdot \rangle$ es el producto interior en $L^2(\mathcal{T})$, $\beta(t)$ es la *función de coeficientes* a estimar y ε_i es un error con media cero independiente de X_i [19, 50]. El producto interior actúa como una versión continua del producto escalar habitual: pondera la curva $X_i(t)$ por $\beta(t)$ en cada instante y acumula esa contribución a lo largo del tiempo. La interpretación de $\beta(t)$ es directa: indica cuánto y en qué sentido influye la forma de la curva en el instante t sobre la respuesta y_i ; un valor grande en módulo señala que la variabilidad de la curva en ese período es especialmente informativa para la predicción.

Estimación mediante componentes principales funcionales.

El problema de estimar $\beta(t)$ directamente a partir de datos es mal condicionado, ya que se trata de recuperar una función de infinitas dimensiones a partir de n observaciones. La estrategia estándar consiste en representar cada curva en una base de dimensión finita y reducir así el problema a una regresión lineal clásica. En este trabajo se emplean las componentes principales funcionales obtenidas en la Sección 6.4 como base de representación [50].

La idea es la siguiente: cada curva X_i se proyecta sobre las primeras K autofunciones $\{v_k\}_{k=1}^K$ para obtener sus scores $\xi_{ik} = \langle X_i, v_k \rangle$. Sustituyendo esta representación en la ecuación (2.30), el producto interior se reduce a una combinación lineal de los scores:

$$y_i = \alpha + \sum_{k=1}^K \xi_{ik} \tilde{b}_k + \varepsilon_i, \quad (2.31)$$

donde $\tilde{b}_k = \langle \beta, v_k \rangle$ son los coeficientes de β en la base PC, que se estiman por mínimos cuadrados ordinarios. El estimador $\hat{\beta}(t)$ se recupera entonces como $\hat{\beta}(t) = \sum_{k=1}^K \hat{\tilde{b}}_k v_k(t)$.

Esta formulación transforma el problema funcional en una regresión multivariante es-

tándar de dimensión K , con propiedades numéricas favorables [50]. Su limitación principal, señalada por Hall et al. [51], es que las primeras componentes capturan la mayor varianza de las curvas predictoras, no necesariamente la información más relevante para predecir y_i ; incluir componentes con autovalores pequeños puede aumentar considerablemente la varianza del estimador. Por ello, la elección de K es un paso crítico: en este trabajo se fija mediante el criterio de varianza acumulada (Sección 6.4) o mediante validación cruzada, según el modelo.

En `fda.usc` [20], `fregre.pc()` estima el modelo (2.31) dado un conjunto de componentes especificado; `fregre.pc.cv()` selecciona automáticamente el subconjunto óptimo de componentes y el parámetro de penalización λ mediante validación cruzada, utilizando el criterio AIC por defecto.

Extensión a múltiples covariables funcionales

En el presente análisis, la potencia media diaria depende simultáneamente de varias curvas meteorológicas. La generalización de (2.30) a p covariables funcionales y eventualmente q covariables escalares es inmediata [47]:

$$y_i = \alpha + \sum_{j=1}^p \langle X_i^{(j)}, \beta^{(j)} \rangle + z_i^\top \gamma + \varepsilon_i, \quad (2.32)$$

donde $X_i^{(j)}$ es la j -ésima curva del día i , $\beta^{(j)}(t)$ su función de coeficientes, y $z_i \in \mathbb{R}^q$ recoge las covariables escalares. Cada función $\beta^{(j)}$ se representa en la base PC obtenida para esa variable, y el ajuste final es una única regresión lineal sobre los scores conjuntos de todas las representaciones.

La función `fregre.lm()` implementa este modelo con una interfaz análoga a `lm()`: la fórmula puede mezclar variables funcionales y escalares, y el argumento `basis.x` asocia a cada variable funcional su base de representación [20].

Evaluación y comparación de modelos

La comparación entre modelos se realiza mediante las métricas de predicción fuera de muestra ya empleadas en el Capítulo 5: el coeficiente de determinación R^2 y la raíz del error cuadrático medio (RMSE), evaluados sobre un conjunto de prueba independiente. La evaluación fuera de muestra es especialmente importante en el contexto funcional: el número efectivo de parámetros crece con K y el riesgo de sobreajuste es no trivial, sobre todo cuando K se selecciona automáticamente sobre los mismos datos de ajuste [47, 52].

Para garantizar comparabilidad con el modelo escalar de referencia, la partición train/test se realiza sobre el subconjunto de días comunes entre el conjunto funcional y el escalar, de modo que todos los modelos se evalúan exactamente sobre los mismos días de prueba.

Metodología y planificación

Este capítulo presenta el marco metodológico y organizativo del trabajo. En él se detallan la metodología adoptada y su adaptación al proyecto, el cronograma de ejecución, la infraestructura tecnológica utilizada (software y hardware) y el presupuesto estimado para su desarrollo.

3.1 Metodología de desarrollo (CRISP-DM)

La metodología que guía el desarrollo de este trabajo es *Cross Industry Standard Process for Data Mining* (CRISP-DM) [53], un marco ampliamente utilizado en el ámbito de la ciencia de datos debido a su enfoque flexible e iterativo. Este modelo se compone de seis etapas principales, que se describen a continuación adaptadas al contexto del presente trabajo.

1. **Comprensión del negocio.** Esta fase engloba el estudio del funcionamiento de la instalación fotovoltaica de Navantia en Ferrol, la identificación de los sistemas de adquisición de datos y la definición del objetivo analítico: modelar y predecir la potencia generada mediante técnicas de análisis multivariante y funcional.
2. **Comprensión de los datos.** Comprende la exploración inicial de los registros de los tres inversores y de los datos meteorológicos, incluyendo el análisis de su estructura, resolución temporal, y posibles inconsistencias derivadas de la zona horaria.
3. **Preparación de los datos.** Abarca el proceso de ETL (del inglés *Extract, Transform, Load*): parseo de los archivos SCADA, corrección de la zona horaria, regularización a rejilla de 10 minutos, integración con los datos meteorológicos, detección de anomalías operativas y construcción de los datasets.
4. **Modelado.** Esta fase se articula en dos bloques metodológicos diferenciados. El primero corresponde al análisis multivariante clásico: detección de atípicos, reducción de dimensionalidad (PCA) y representación gráfica en dimensión reducida (MDS), segmentación

mediante *clustering* y modelos de regresión (regresión lineal múltiple y Random Forest). El segundo bloque aplica análisis de datos funcionales: suavizado mediante bases, análisis de profundidad funcional, detección de curvas atípicas, componentes principales funcionales (FPCA) y regresión funcional.

5. **Evaluación.** Los modelos de regresión se evalúan mediante validación cruzada repetida de cinco particiones y métricas RMSE y R^2 sobre el conjunto de test.
6. **Despliegue.** Esta fase se materializa en la síntesis de conclusiones, la identificación de limitaciones del estudio y la propuesta de líneas de trabajo futuro.

3.2 Planificación temporal

Para garantizar la viabilidad del proyecto y asegurar el cumplimiento de los plazos académicos, el desarrollo del trabajo se ha estructurado de manera cronológica en siete fases diferenciadas. A continuación, en la Figura 3.1, se presenta el cronograma detallado del proyecto mediante un diagrama de Gantt que cubre el período comprendido entre febrero y junio.

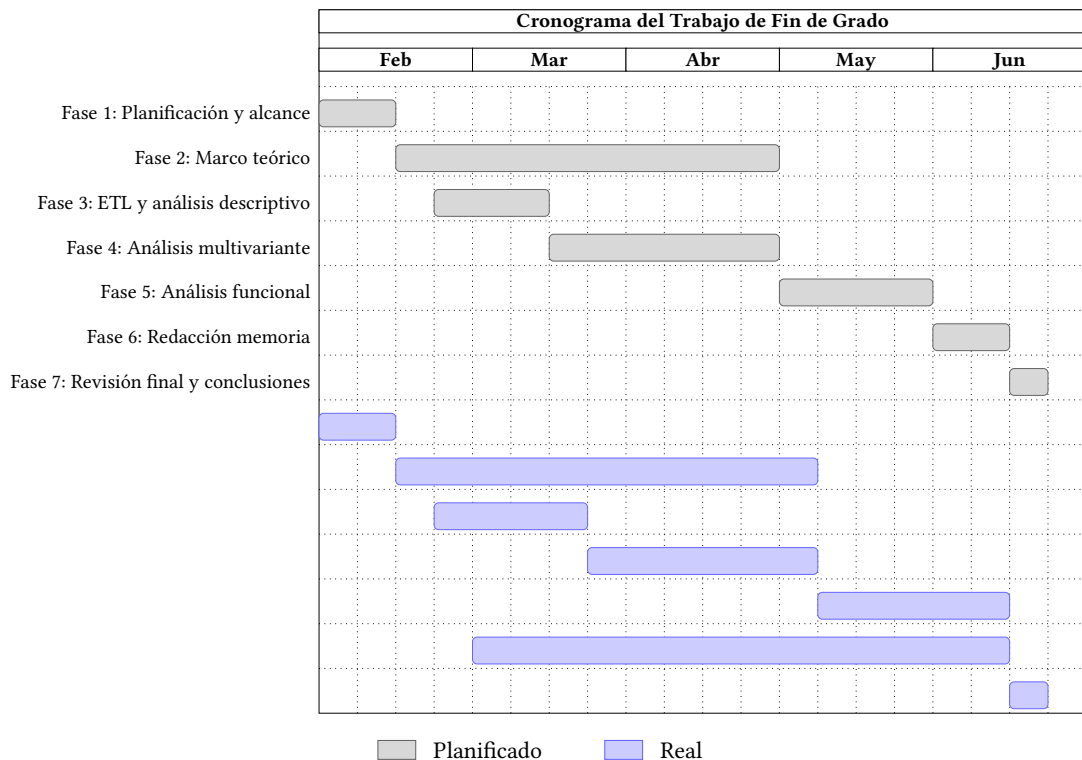


Figura 3.1: Diagrama de Gantt con la planificación temporal del proyecto.

3.3 Herramientas

En esta sección se describen los recursos técnicos y las herramientas tecnológicas empleadas para el desarrollo y ejecución de este proyecto. Con el objetivo de garantizar un flujo de trabajo robusto y reproducible, el entorno de trabajo se desglosa en dos pilares fundamentales: por un lado, el ecosistema de software especializado en el análisis estadístico de datos y, por otro, la infraestructura de hardware que sirvió como soporte físico tanto para las tareas de computación como para la redacción de la presente memoria.

3.3.1 Ecosistema de software

Para la implementación del flujo de trabajo descrito, se ha seleccionado un ecosistema de software basado en el análisis de datos de código abierto.

- **Lenguaje R (v4.3.1):** R es un lenguaje de programación y un entorno integrado diseñado específicamente para el cómputo estadístico y la generación de gráficos. Basado en el lenguaje S, se distingue por ser un sistema coherente y planificado en lugar de una agrupación de herramientas aisladas, lo que facilita la manipulación de datos, el cálculo matricial y la visualización de alta calidad [54].
- **RStudio IDE:** Como entorno de desarrollo integrado, RStudio facilita la gestión de proyectos, la depuración de scripts y la generación de informes dinámicos [55].
- **LaTeX y Overleaf:** La redacción de la memoria se ha realizado en LaTeX, un sistema de composición tipográfica adoptado en la literatura científica y técnica por su capacidad para gestionar fórmulas matemáticas complejas, referencias bibliográficas y estructuras documentales de forma coherente [56]. Como entorno de edición colaborativo en línea se ha empleado Overleaf [57].

3.3.2 Infraestructura de hardware

La totalidad del proyecto se ha llevado a cabo en un portátil MacBook Air, equipado con un procesador Apple M4 y 16 GB de memoria RAM. Este ordenador ha servido como la unidad principal de cómputo y edición. Su uso ha garantizado la fluidez necesaria tanto para las tareas de programación en R como para la composición de la memoria.

3.4 Costes

Este apartado detalla el presupuesto del proyecto. Cabe destacar que no se contemplan costes de software, ya que el desarrollo se ha realizado íntegramente utilizando herramientas de software libre y de código abierto.

3.4.1 Costes de personal

Para cuantificar el coste del capital humano, se ha calculado el precio por hora de cada perfil estimando una jornada laboral estándar de 1 720 horas al año:

- **Ingeniero de datos junior:** El desarrollo de este Trabajo de Fin de Grado equivale a un total de 12 créditos ECTS, lo que se traduce normativamente en 300 horas de dedicación. Tomando como referencia el salario medio actual en España para un ingeniero de datos junior (26 000 € brutos anuales), se establece un coste por hora de 15,12 €/h [58].
- **Profesora Permanente Laboral - PPL-LOSU:** De acuerdo con las [tablas retributivas de PDI laboral de la UDC para el ejercicio 2026](#), la categoría de Profesora Permanente Laboral a tiempo completo cuenta con una asignación bruta anual de 40 291,94 €. Esto determina un coste por hora de 23,43 €/h. Se estima una dedicación de 20 horas asignadas a la tutorización técnica y revisión del proyecto.
- **Profesor Ayudante Doctor - AXU-DR-LOSU:** Según el documento oficial citado en el punto anterior, la figura de Profesor Ayudante Doctor a tiempo completo bajo el marco LOSU percibe una retribución anual de 33 092,08 € brutos. Esto sitúa su coste por hora en 19,24 €/h, contemplando una dedicación de 20 horas destinadas a la dirección académica del trabajo.
- **Responsable de mantenimiento - Navantia Ferrol:** Para su perfil profesional, correspondiente a un ingeniero industrial senior, se establece un precio por hora de referencia de 50 €/h, considerando una dedicación de 3 horas destinadas a la orientación del proyecto.

A continuación, se presenta el desglose y sumatorio total de los costes estimados:

Tabla 3.1: Resumen de los costes estimados del proyecto.

Perfil	Coste total
Ingeniero de datos junior	4 536,00 €
Profesora Permanente Laboral	468,60 €
Profesor Ayudante Doctor	384,80 €
Responsable de mantenimiento Navantia Ferrol	150,00 €
Total estimado	5 539,40 €

Datos y análisis exploratorio

Para el desarrollo de este Trabajo de Fin de Grado, la recopilación y comprensión de los datos de origen constituye un pilar fundamental. Dada la magnitud del astillero de Navantia en Ferrol y con el objetivo de realizar un análisis exhaustivo y controlado, el alcance de este proyecto se ha acotado a una única infraestructura: la instalación fotovoltaica del taller de módulos y reparaciones.

4.1 Instalación fotovoltaica

El despliegue de esta infraestructura supuso una inversión directa de 284 162€ [59], contando con la financiación de los fondos europeos *Next Generation* (asociados al PERTE Naval). El retorno energético y financiero de este activo industrial justifica la necesidad de implantar sistemas de modelado predictivo como el propuesto en este trabajo.

A nivel de hardware, los datos técnicos de la instalación analizada son los siguientes:

- **Módulos fotovoltaicos:** La captación solar se realiza a través de 677 paneles modelo *SOLYCO R-TG 108n.3 / 420*, de los cuales 222 están sobre el Taller de Reparaciones (6 strings de 37 módulos cada uno) y 455 sobre el Taller de Módulos (13 strings de 35 módulos cada uno). Al tratarse de módulos de 420 Wp, el conjunto de la instalación proporciona una potencia teórica en torno a los 284,34 kWp bajo condiciones ideales ¹.
- **Inversores:** La transformación de la corriente continua a corriente alterna, y principal punto de adquisición de datos para este trabajo, se lleva a cabo mediante inversores de la serie *KACO BLUEPLANET 100 NX3* (véase Figura A.1 del Anexo). Cada uno de estos inversores tiene una potencia nominal de 100 kW.

¹ Conocidas en la industria como Condiciones Estándar de Medida (STC, por sus siglas en inglés): Radiación de 1 000 W/m², Modificador del Ángulo de Incidencia (AM) de 1,5 y Temperatura de célula de 25 °C.

4.2 Registros del SCADA

La variable respuesta para el desarrollo de los modelos predictivos es la potencia eléctrica generada por la instalación fotovoltaica. Esta información se extrae del sistema de monitorización y control (SCADA) que supervisa los tres inversores de la planta, cuya interfaz se muestra en la Figura 4.1. Los históricos de producción se descargaron en tres ficheros independientes, uno por cada inversor físico. El rango temporal de las lecturas del SCADA comprende desde el **4 de noviembre de 2024** hasta el **2 de marzo de 2026**. La Tabla 4.1 resume el volumen de datos asíncronos capturados.



Figura 4.1: Interfaz SCADA del sistema fotovoltaico del taller de reparaciones, con las lecturas en tiempo real de los tres inversores KACO y la potencia total generada.

Tabla 4.1: Volumen de registros asíncronos capturados por el sistema SCADA.

Inversor	Registros asíncronos
<i>Inversor 1</i>	668 482
<i>Inversor 2</i>	678 051
<i>Inversor 3</i>	679 811
Total	2 026 344

Las características principales de estos registros son las siguientes:

- **Variable extraída:** Potencia de salida en corriente alterna, medida en kilovatios (kW). Esta métrica cuantifica la energía final generada por las líneas de paneles tras la conversión CC/CA del inversor.
- **Estructura de datos asíncrona:** A diferencia de las estaciones meteorológicas, el sistema SCADA registra datos de forma asíncrona, capturando cambios de potencia con resoluciones temporales de hasta milisegundos. Como se observa en la Tabla A.1, estos valores se reciben en instantes distintos dentro de un mismo intervalo, lo que requiere un proceso de regularización y promediado posterior.

4.3 Datos meteorológicos: CIS Ferrol

La generación de energía solar fotovoltaica es un proceso altamente dependiente de las condiciones atmosféricas. Después de realizar un estudio interno sobre la fiabilidad de las estaciones meteorológicas de Navantia, se optó por prescindir de los sensores de la propia planta y recurrir a la red de observación de MeteoGalicia [60]. Esta decisión se fundamenta en la alta disponibilidad de los datos de la red pública y en la proximidad geográfica de la estación CIS Ferrol. Se encuentra situada en la zona de A Cabana (Ferrol), a aproximadamente 2,7 km en línea recta de las instalaciones de Navantia, en las coordenadas geográficas $43,491467^\circ$ N, $-8,252274^\circ$ W y a una altitud de 37 m sobre el nivel del mar [61] (véase Figura 4.2).




Figura 4.2: Localización de la planta fotovoltaica de Navantia Ferrol (azul) y de la estación meteorológica CIS Ferrol de MeteoGalicia (naranja).

Las variables meteorológicas empleadas, todas ellas registradas con una resolución temporal diezminutal, se resumen en la Tabla 4.2.

Tabla 4.2: Variables meteorológicas extraídas de la estación CIS Ferrol.

Variable	Descripción	Unidad
Radiación solar	Irradiancia en el plano horizontal	W/m ²
Temperatura	Temperatura del aire a 1,5 m del suelo	°C
Humedad relativa	Humedad relativa del aire	%
Precipitación	Precipitación acumulada en 10 min	L/m ²
Velocidad del viento	Velocidad media del viento a 10 m	km/h
Presión	Presión atmosférica al nivel de la estación	hPa

La descarga de los datos meteorológicos se realizó a través del portal de datos abiertos de MeteoGalicia, lo cual requirió múltiples descargas parciales al haber límites de consulta. Posteriormente, fueron concatenadas en un único fichero. El rango temporal es ligeramente más amplio que el histórico disponible de los datos SCADA. Esta holgura garantizó una cobertura temporal total, asegurando que todos los registros de producción fotovoltaica dispusieran de su correspondiente información climática.

4.4 Integración y preprocesamiento

La construcción del dataset requirió un proceso de integración entre las fuentes SCADA y meteorológica, así como diversas transformaciones para garantizar la coherencia temporal. Este apartado detalla las etapas llevadas a cabo: la alineación de zonas horarias, la regularización a intervalos diezminutales, la agregación diaria de variables y la exclusión de anomalías operativas.

4.4.1 Sincronización de zonas horarias

La correcta integración del sistema SCADA y la información meteorológica exigió un paso previo de alineación temporal hacia una escala UTC homogénea, dado que cada fuente empleaba su propio estándar. Por un lado, los registros SCADA operaban en hora local española (Europa/Madrid), por lo que su conversión a UTC se resolvió mediante un cambio de huso horario estándar. Por el contrario, los datos abiertos de MeteoGalicia presentaban un desfase

sistemático de entre 1 y 2 horas; este error se originó al aplicar erróneamente una corrección de huso local a registros que, de origen, ya se encontraban en UTC. De no corregirse, este error asignaría variables climáticas a instantes de producción incorrectos. La corrección se implementó en R mediante tres operaciones sucesivas apoyadas en el paquete `lubridate`:

1. Se forzó la lectura inicial interpretando literalmente la marca temporal del fichero como instante UTC.
2. Se reevaluó el registro hacia el huso Europa/Madrid mediante la función `with_tz()`, recuperando así la hora original de medida de la estación.
3. Se fijó de forma permanente este valor recuperado como el instante UTC verdadero mediante `force_tz()`, obteniendo una escala homologable con el SCADA para el cruce por fecha (*join*).

4.4.2 Regularización a intervalos de 10 minutos

Para posibilitar el cruce exacto con la rejilla diezminutal de MeteoGalicia, se implementó un algoritmo de regularización en tres pasos:

1. **Discretización temporal:** Cada marca temporal se asigna al inicio del intervalo de 10 minutos que la contiene.
2. **Agregación por promedio:** Se calcula la media aritmética de todas las lecturas asíncronas dentro de cada intervalo, preservando la magnitud física de la potencia y suavizando fluctuaciones de alta frecuencia.
3. **Potencia total:** Los tres inversores se integran mediante un cruce temporal completo. La potencia AC total en cada intervalo es:

$$\text{Potencia}_{\text{Total}}(t) = \sum_{i=1}^n \text{Potencia}_{\text{Inv}_i}(t), \quad n = 3, \quad i \in \{1, 2, 3\} \quad (4.1)$$

El resultado son **32 165** registros diezminutales para el periodo de monitorización.

4.4.3 Agregación diaria de variables

El análisis multidimensional se realiza a escala diaria, transformando los registros diezminutales en resúmenes de 24 horas mediante dos criterios diferenciados. Para las variables meteorológicas, al tratarse de registros continuos, se calculó la media aritmética de la radiación solar, la temperatura, la humedad relativa, la velocidad del viento, y la presión atmosférica; la precipitación, en cambio, se obtiene como suma acumulada diaria para reflejar el total real

caído. Para las variables de producción, la potencia media diaria se calcula promediando exclusivamente las lecturas disponibles en las horas con actividad registradas por los inversores; este criterio evita el sesgo que introduciría incorporar horas nocturnas sin registro. Ambos resúmenes diarios se integraron preservando todos los días con datos meteorológicos; los días sin registro de producción figuran con valores nulos en las variables de potencia.

El resultado es el dataset diario con **484 días** comprendidos entre el 4 de noviembre de 2024 y el 2 de marzo de 2026. Adicionalmente, las variables de calendario (mes, día de la semana y una variable binaria de día no laborable que identifica fines de semana y festivos nacionales y autonómicos gallegos) se reconstruyen para la totalidad de los días.

4.4.4 Exclusión de anomalías operativas

Siguiendo el enfoque propuesto por Facchinetti et al. [62], que define la anomalía de producción nula durante el día como aquella situación en la que un sistema fotovoltaico no genera potencia a pesar de disponer de recurso solar suficiente, se adoptó el criterio:

$$\text{Anomalía} = (\overline{P}_{\text{Total}} < 1 \text{ kW}) \wedge (\overline{R}_{\text{Solar}} > 50 \text{ W/m}^2) \quad (4.2)$$

Este criterio detectó **15 días anómalos**: 14 días consecutivos entre el 28 de julio y el 10 de agosto de 2025 (parada técnica estival) y un día aislado el 7 de noviembre de 2025. Tras excluir estos 15 días anómalos y los 37 días sin datos de producción registrados (correspondientes al exceso de cobertura temporal del dataset meteorológico), se obtuvo el conjunto de datos limpio con **432 días**.

4.5 Estudio descriptivo

Esta sección examina las variables individualmente y sus relaciones bivariantes. El objetivo es caracterizar la tendencia y dispersión de cada indicador, así como identificar dependencias lineales y estructuras de asociación previas al análisis multivariante.

4.5.1 Análisis univariante

El análisis univariante examina cada variable de forma individual sobre el conjunto de datos diario agregado ($n = 432$ días). Para cada indicador se calculan los estadísticos de tendencia central (media y mediana), dispersión (desviación estándar, DE) y rango (mínimo y máximo), recogidos en la Tabla 4.3. Las variables de producción se obtienen promediando los registros de las horas con irradiancia positiva, mientras que las variables meteorológicas incorporan las 24 horas del día para evitar sesgos hacia el periodo diurno. Con el fin de facilitar la lectura de la tabla, los nombres de las variables se presentan en forma abreviada.

Tabla 4.3: Estadísticas descriptivas de las variables diarias.

Variable	Media	Mediana	DE	Mín	Máx
Pot_Media	64,85	64,73	32,76	0	136,88
Rad_Media	141,82	108,18	99,12	0	369,82
Temp_Media	14,65	14,51	3,89	6,21	24,45
Hum_Rel	77,36	78,31	7,65	49,33	93,80
Precip	4,62	0,25	9,03	0	80,80
Viento_vel	9,66	8,54	5,43	0,83	26,74
Presion	1014,02	1014,96	8,17	980,47	1033,49

La Tabla 4.3 resume las estadísticas descriptivas de las variables diarias principales tras el proceso de agregación. Para visualizar la forma de las distribuciones y complementar las estadísticas tabulares, se presentan a continuación histogramas para cada variable. En todos ellos, la curva roja sobrepuesta representa la estimación no paramétrica de la densidad mediante el método de kernel gaussiano.

En la Figura 4.3a se observa que la distribución de la **potencia media** presenta una naturaleza bimodal. Un valle intermedio, situado cerca de la media (64,85 kW) y la mediana (64,73 kW) globales, separa dos regímenes de funcionamiento que reflejan la alternancia entre la estabilidad anticiclónica y la inestabilidad de los frentes atlánticos. Aunque la potencia nominal es de 300 kW, el máximo diario de 136,88 kW se justifica por el efecto del promedio temporal, frente a picos instantáneos que sí rozan la capacidad nominal (289,87 kW). Esta bimodalidad encuentra su explicación cronológica en el análisis estacional (Figura 4.3b). En dicho gráfico se aprecia un contraste entre el periodo primavera-verano, con medianas superiores a los 80 kW, y el invierno, donde la producción cae al rango de los 30–50 kW.




Figura 4.3: Análisis univariante de la potencia media diaria.

A continuación se analiza la distribución de las variables meteorológicas, cuya variabilidad explica en gran medida los patrones de producción observados.




Figura 4.4: Distribución de las variables radiación y temperatura.

La Figura 4.4 revela que la **radiación solar** presenta una marcada asimetría positiva, con una media ($141,82 \text{ W/m}^2$) significativamente superior a la mediana ($108,18 \text{ W/m}^2$) y una elevada desviación típica ($\sigma = 99,12 \text{ W/m}^2$), lo que refleja una alta variabilidad entre días. Esta tendencia se traduce en una mayor frecuencia de días con baja insolación y una cola extendida hacia valores máximos de $369,82 \text{ W/m}^2$.

Por su parte, la **temperatura media** muestra un comportamiento más estable y acotado entre los $6,21 \text{ }^\circ\text{C}$ y $24,45 \text{ }^\circ\text{C}$, con una oscilación térmica anual moderada ($\sigma = 3,89 \text{ }^\circ\text{C}$). A diferencia de la radiación, la temperatura exhibe una distribución bimodal: un primer máximo en torno a los $11\text{--}12 \text{ }^\circ\text{C}$ y un segundo pico hacia los $19\text{--}20 \text{ }^\circ\text{C}$. Esta bimodalidad, suavizada por la influencia termorreguladora del Atlántico [63], subraya la estacionalidad del dataset.




Figura 4.5: Distribución de las variables de humedad y precipitación.

El perfil higrométrico de la instalación (Figura 4.5) confirma el carácter atlántico de la ubicación. La **humedad relativa** presenta una marcada asimetría negativa, con una media del 77,36 % y una mediana del 78,31 %. La estimación tipo núcleo de la densidad revela un máximo predominante en torno al 80 %, indicando que la alta humedad es la norma operativa. Los valores por debajo del 65 % son escasos y se asocian a episodios anticiclónicos secos.

En contraste, la **precipitación acumulada** exhibe la asimetría positiva más extrema del estudio. La drástica diferencia entre la media ($4,62 \text{ L/m}^2$) y la mediana ($0,25 \text{ L/m}^2$) evidencia que la mayoría de las jornadas registran lluvias nulas o mínimas, mientras que una cola derecha muy extendida (con eventos extremos de hasta $80,80 \text{ L/m}^2$) representa el impacto de los frentes atlánticos. Es importante destacar que, para la producción fotovoltaica, la ausencia de lluvia no garantiza una alta irradiancia, ya que la nubosidad persistente suele reducir la radiación incidente sin generar precipitación apreciable.




Figura 4.6: Distribución de las variables de viento y presión atmosférica.

El estudio de la dinámica atmosférica (Figura 4.6) completa la caracterización meteorológica del emplazamiento. La **velocidad del viento** exhibe una asimetría positiva moderada, con una media de 9,66 km/h y una mediana de 8,54 km/h. Aunque predominan las jornadas de vientos suaves, la presencia de una cola derecha hasta los 26,74 km/h evidencia episodios aislados de fuerte viento.

Por el contrario, la **presión atmosférica** es la variable que presenta mayor simetría y concentración, con un perfil unimodal centrado en los 1014,02 hPa ($\sigma = 8,17$ hPa). Su leve asimetría negativa identifica la incursión ocasional de borrascas profundas (mínimo de 980,47 hPa) frente a la estabilidad predominante de los periodos anticiclónicos, los cuales alcanzan máximos de 1033,49 hPa.

Detección de atípicos univariantes

Complementando el análisis descriptivo anterior, se aplicó la regla de Tukey [64] para identificar observaciones extremas en cada variable de forma independiente.

Para una variable dada, un valor x_i se clasifica como atípico si supera los límites:

$$x_i < Q_1 - 1,5 \cdot \text{IQR} \quad \text{o} \quad x_i > Q_3 + 1,5 \cdot \text{IQR}, \quad (4.3)$$

donde Q_1 y Q_3 son el primer y tercer cuartil de la variable, e $\text{IQR} = Q_3 - Q_1$ es el rango intercuartílico. Mientras que las variables de producción y temperatura carecen de valores atípicos, se identificaron anomalías en el resto de variables meteorológicas:

- **Precipitación (37 días) y viento (4 días):** Atípicos superiores asociados a borrascas y vientos intensos.
- **Presión (16 días) y humedad (9 días):** Atípicos inferiores correspondientes a situaciones ciclónicas o jornadas inusualmente secas.

Dado que los 66 días afectados representan el 15,3 % del dataset y que todos los valores extremos son climáticamente coherentes con la realidad meteorológica de Ferrol ², se optó por mantenerlos en el análisis posterior para no perder información relevante.

4.5.2 Análisis bivariante

Con el objetivo de explorar la relación entre la producción fotovoltaica y cada una de las variables meteorológicas registradas, se presentan a continuación los diagramas de dispersión de la potencia AC media diaria frente a cada predictor. En todos los casos se superpone una

² Los valores extremos detectados en precipitación son consistentes con la climatología documentada de Ferrol, donde la precipitación media anual supera los 1 000 mm y son frecuentes los episodios de lluvia intensa asociados al paso de frentes atlánticos, especialmente entre octubre y marzo [65].

recta de regresión lineal simple con su intervalo de confianza al 95 %, con el fin de identificar visualmente la dirección e intensidad de la asociación. Las relaciones cuantificadas mediante el coeficiente de correlación de Pearson se analizan en detalle en la sección siguiente.




Figura 4.7: Relación de la potencia con los principales factores meteorológicos.

La relación entre la **potencia y la radiación solar** es la más intensa y directa del estudio; la nube de puntos se ajusta a la recta de regresión con una dispersión mínima, confirmando que la irradiancia es el factor primario de la producción fotovoltaica.

Por otro lado, la **potencia y la temperatura** presentan una asociación lineal positiva moderada. La temperatura actúa aquí como una variable *proxy* de la estacionalidad: los valores térmicos elevados coinciden con meses de mayor insolación, induciendo una correlación que no implica causalidad directa. La mayor dispersión observada en este segundo gráfico, refuerza la idea de que la temperatura no define el potencial de generación de forma aislada.




Figura 4.8: Relación de la potencia con variables de humedad y lluvia.

El análisis de la Figura 4.8 muestra cómo los factores hídricos condicionan la producción. La **humedad relativa** presenta una asociación lineal negativa clara; los valores elevados de

humedad se vinculan a cielos cubiertos o nieblas que merman la radiación incidente. No obstante, la dispersión aumenta en rangos intermedios, indicando que la relación entre nubosidad y humedad no es unívoca.

Antes de interpretar la relación con la precipitación, cabe señalar que esta variable presenta una notable concentración de valores nulos: de los 432 días incluidos en el análisis, 184 (el 42,6 %) registran precipitación acumulada diaria igual a 0 L/m². Este comportamiento fue verificado directamente en el portal de MeteoGalicia, confirmando que se trata de datos correctos y no de errores de medición. Por ello, se decidió mantener estos valores en el análisis sin imputación. Dicho esto, la relación con la **precipitación** exhibe una estructura condicionada por el fuerte sesgo de la variable (concentración en valores nulos). Aunque la recta de regresión muestra pendiente negativa, el ensanchamiento del intervalo de confianza ante lluvias elevadas evidencia las limitaciones de los modelos lineales simples para esta variable.




Figura 4.9: Relación de la potencia con la dinámica barométrica y eólica.

El análisis de la dinámica atmosférica (Figura 4.9) revela asociaciones de carácter indirecto. La **presión atmosférica** exhibe una asociación positiva moderada; los regímenes anticiclónicos (>1015 hPa) suelen vincularse a una mayor estabilidad, favoreciendo la irradiancia. Sin embargo, la alta dispersión en niveles de presión elevados confirma que la estabilidad barométrica no es una condición suficiente para predecir la producción de forma aislada.

Por su parte, el **viento** presenta la asociación lineal más débil de todo el conjunto analizado, con una tendencia ligeramente negativa. Esta pendiente descendente responde a que los vientos intensos suelen acompañar a frentes e inestabilidad, reduciendo la captación solar. No obstante, la elevada dispersión de la nube de puntos, especialmente en velocidades bajas, sugiere que el viento es el predictor con menor capacidad explicativa individual, actuando más como un indicador de situaciones de temporal que como un factor directo de la eficiencia en este emplazamiento.

4.5.3 Análisis de correlación

La cuantificación del grado de asociación entre las variables meteorológicas y la producción se ha abordado mediante un análisis comparativo entre la correlación de Pearson (Figura 4.10) y la correlación de distancias de Székely (Figura 4.11). Este enfoque permite distinguir entre asociaciones puramente lineales y dependencias estructurales más complejas.




Figura 4.10: Correlación de Pearson.




Figura 4.11: Correlación de distancias.

La comparativa de correlaciones ratifica a la radiación como el predictor dominante. La superioridad del coeficiente de Székely ($\mathcal{R} = 0,88$) frente al de Pearson ($r = 0,86$) sugiere que la dependencia entre ambas variables posee una naturaleza parcialmente no lineal.

Por otro lado, la precipitación ($r = -0,46$) y la humedad ($r = -0,42$) presentan correlaciones negativas moderadas en el análisis lineal, las cuales se ven reforzadas al emplear la métrica de Székely ($\mathcal{R} = 0,53$ y $0,41$, respectivamente). Este aumento evidencia dependencias no lineales que la estadística clásica tiende a subestimar.

La presencia de multicolinealidad moderada entre radiación y temperatura ($r = 0,60$) justifica el empleo de técnicas de reducción dimensional. Por otro lado, la correlación entre los inversores ($r = 0,98$) avala el uso de la potencia agregada como variable respuesta. Finalmente, el hecho de que todas las variables meteorológicas presenten una dependencia no nula ($\mathcal{R} \neq 0$ en la prueba de Székely) confirma su relevancia estadística, reforzando la necesidad de un enfoque multivariante para la identificación de regímenes operativos.

Análisis multivariante

Este capítulo presenta el análisis multivariante aplicado a los datos diarios escalares, abordando la detección de outliers, la reducción de dimensión, la agrupación de días mediante *clustering* y el modelado de la potencia mediante regresión.

5.1 Detección de outliers

Como ya se describió con detalle en la Sección 2.3.2 del marco teórico, el algoritmo Local Outlier Factor (LOF) asigna a cada observación un score basado en la comparación de su densidad local con la de sus k vecinos más próximos. Tras analizar la distribución de los *scores* obtenidos (ver Figura A.2 del Anexo), se estableció un umbral de detección de LOF = 2. La elección de este valor responde a dos criterios. En primer lugar, desde el punto de vista gráfico, la figura de densidad muestra que la masa principal de los scores se concentra en torno a 1, con una cola derecha escasa y bien separada del cuerpo central: los tres días que superan el umbral de 2 emergen como discontinuidades naturales en dicha cola, no como el resultado de una elección arbitraria del corte. En segundo lugar, desde el punto de vista metodológico, Breunig et al. [26] establecen que los objetos pertenecientes a una región densa presentan valores LOF ≈ 1 , mientras que valores sustancialmente superiores reflejan un aislamiento local significativo. De los 432 días analizados, los siguientes 3 días superaron dicho umbral:

- **3 de enero y 24 de febrero de 2025:** Ambos son jornadas invernales con temperaturas inusualmente cálidas para su época (13–14 °C) combinadas con lluvias torrenciales excepcionales (80,8 y 76,3 L/m², respectivamente), una combinación que los aísla localmente del comportamiento típico de los días circundantes de enero y febrero.
- **27 de julio de 2025:** Corresponde a la jornada de inicio de la parada técnica estival. Con una radiación solar de 305,93 W/m² la planta tan solo generó 1,26 kW al comenzar el proceso de desconexión programada.

Dado el reducido número de atípicos detectados (0,69 %) y que se distancian claramente del comportamiento general, se optó por **excluirlos del análisis multivariante**, trabajando sobre un conjunto final de **429 días válidos**.

5.2 Análisis de componentes principales (PCA)

El análisis de componentes principales (PCA) constituye la primera técnica de reducción de la dimensión aplicada al conjunto de datos diario. El análisis se estructura en dos variantes con objetivos complementarios: la primera examina los tres inversores por separado, y la segunda aplica el PCA sobre el conjunto completo de variables meteorológicas y de producción. En los dos casos se emplea la función `prcomp()` de R, basada en descomposición en valores singulares (SVD) sobre la matriz de varianzas-covarianzas, con estandarización previa de las variables, lo que es equivalente a aplicar el PCA sobre la matriz de correlaciones.

5.2.1 PCA sobre los inversores

Se aplica PCA sobre las potencias medias diarias de los tres inversores con el objetivo de verificar si estos son redundantes y si la variable *Pot_Media* (media de los tres) los resume sin pérdida de información relevante.

Tabla 5.1: Varianza explicada por las componentes principales del PCA sobre los tres inversores.

Componente	Desviación típica	Proporción de varianza
PC1	1,7263	0,9933
PC2	0,13737	0,0063
PC3	0,03433	0,0004

Los resultados muestran que la primera componente principal (PC1) absorbe el 99,33 % de la varianza total. Las componentes segunda y tercera recogen únicamente el 0,63 % y el 0,04 % de la varianza respectivamente, correspondientes a pequeñas discrepancias puntuales entre inversores sin relevancia analítica. De acuerdo con el criterio de Kaiser, se retiene únicamente PC1, dado que, como se puede observar en el Anexo A.2 es la única que presenta un autovalor superior a la unidad ($\lambda_1 = 2,98$).

Tabla 5.2: *Loadings* de las componentes principales del PCA sobre los tres inversores.

Variable	PC1	PC2	PC3
<i>Pot_Inv1</i>	0,5758	−0,79492	−0,1913
<i>Pot_Inv2</i>	0,5788	0,2311	0,7821
<i>Pot_Inv3</i>	0,5774	0,5610	−0,5931

Los *loadings* de PC1 son positivos y presentan una magnitud prácticamente idéntica para los tres inversores (0,5758, 0,5788 y 0,5774). Esta homogeneidad confirma que PC1 representa la producción conjunta y equilibrada de la instalación. Por el contrario, la segunda y tercera componente principal (PC2 y PC3) recogen contraposiciones entre inversores específicos; no obstante, dado que ambas componentes explican en conjunto menos del 1 % de la varianza total, no se consideran relevantes en este trabajo. Queda así justificado el uso de la potencia media como variable única de producción para los análisis posteriores, tanto en el estudio multivariante clásico como en el funcional.

5.2.2 PCA sobre todas las variables

Se aplica PCA sobre el conjunto completo de variables meteorológicas y de producción con el objetivo de identificar las combinaciones lineales que concentran la mayor parte de la variabilidad entre días y visualizar tipologías de comportamiento.

Tabla 5.3: Varianza explicada por las componentes principales del PCA sobre todas las variables.

Componente	Desviación típica	Prop. varianza
PC1	1,6944	41,01 %
PC2	1,3182	24,82 %
PC3	0,9244	12,21 %
PC4	0,80047	9,154 %
PC5	0,71634	7,331 %
PC6	0,54487	4,241 %
PC7	0,29334	1,229 %

El análisis de componentes principales aplicado al conjunto de las siete variables (Tabla 5.3) revela una estructura de varianza más distribuida que en el caso previo de los inversores. Las dos primeras componentes explican de forma conjunta el 65,83 % de la información total.

Siguiendo el criterio de Kaiser, se retienen únicamente estas dos componentes por presentar autovalores superiores a la unidad. El desglose detallado de los autovalores para cada componente puede consultarse en el Anexo A.2.

Tabla 5.4: *Loadings* de las dos componentes principales retenidas del PCA sobre todas las variables.

Variable	PC1	PC2
<i>Pot_Media</i>	0,535	0,007
<i>Rad_Media</i>	0,539	−0,118
<i>Temp_Media</i>	0,340	−0,314
<i>Hum_Rel</i>	−0,293	0,412
<i>Precip</i>	−0,398	−0,264
<i>Viento_Vel</i>	−0,110	−0,631
<i>Presion</i>	0,226	0,500

El análisis de los factores de carga (Tabla 5.4) permite interpretar el significado físico de las dos componentes retenidas. PC1 presenta cargas positivas elevadas en *Pot_Media* (0,535) y *Rad_Media* (0,539), y cargas negativas en *Precip* (−0,398) y *Hum_Rel* (−0,293), lo que permite interpretarla como un eje de radiación y producción: los días con puntuación alta en PC1 son días soleados y productivos, mientras que los días con puntuación baja corresponden a días lluviosos y con escasa generación. PC2, por su parte, contrapone *Viento_Vel* (−0,631) frente a *Presion* (0,500) y *Hum_Rel* (0,412), configurándose como un eje de condiciones dinámicas atmosféricas: días ventosos y de baja presión frente a días estables y húmedos sin viento. De hecho, *Pot_Media* tiene una carga prácticamente nula en PC2 (0,007), lo que confirma que la producción fotovoltaica queda explicada por el eje de radiación (PC1).

5.3 Escalamiento multidimensional

Otro punto de interés en el análisis multivariante es la representación de las relaciones entre las variables en un espacio de dimensión reducido. Para ello, se estudió la estructura de relaciones entre las variables mediante MDS clásico sobre las 7 variables continuas. Con ese

fin, se construyó una matriz de distancias 7×7 a partir de las correlaciones de Pearson usando la transformación definida en la ecuación (2.5), que sirvió como entrada al algoritmo.

Para determinar la dimensión de representación, se calcularon los autovalores de la matriz de productos escalares centrados obtenida a partir de D . Como se recoge en la Tabla A.3 del Anexo, los dos primeros autovalores ($\lambda_1 = 2,653$ y $\lambda_2 = 1,706$) son dominantes respecto al resto, lo que justifica la elección de una representación bidimensional ($k = 2$).




Figura 5.1: Mapa de similitud entre variables mediante MDS clásico.

El mapa resultante (Figura 5.1) revela una estructura con tres agrupaciones diferenciadas:

- **Bloque de producción solar (cuadrante izquierdo):** *Pot_Media* y *Rad_Media* aparecen como los dos puntos más próximos del mapa, confirmando que la potencia generada y la radiación solar incidente presentan una dinámica muy similar a lo largo del período de estudio. *Temp_Media* se sitúa en una posición adyacente a este bloque, reflejando su asociación indirecta con ambas variables a través de la estacionalidad.
- **Bloque atmosférico adverso (cuadrante superior derecho):** *Hum_Rel* y *Precip* se posicionan en el extremo opuesto al bloque de producción, confirmando visualmente su correlación negativa con la potencia. *Presion* se sitúa próxima a este bloque, lo que refleja que en el clima atlántico de Ferrol la presión atmosférica no actúa como predictor directo de días despejados, sino que aparece asociada al régimen de humedad y frentes.
- **Viento (cuadrante inferior derecho):** *Viento_Vel* ocupa una posición aislada, evidenciando su escasa covariación con los demás predictores y con la producción fotovoltaica.

5.4 Análisis clustering

En el marco del análisis multivariante, otro aspecto relevante es estudiar los tipos de agrupaciones que se formarían para los individuos de la muestra, en este caso, los días. Con el fin de identificar patrones de comportamiento en la producción fotovoltaica y segmentar los días bajo condiciones similares, se proponen dos estrategias complementarias. Estas se diferencian por el conjunto de variables seleccionadas (de producción o meteorológicas y de producción), permitiendo observar la estructura de los datos desde distintas perspectivas. Previo a la ejecución del algoritmo, las variables se estandarizaron, dado que presentan unidades y magnitudes heterogéneas (W/m^2 , $^{\circ}\text{C}$, hPa, etc.). Este paso garantiza que cada variable aporte el mismo peso al cálculo de la distancia euclídea entre observaciones.

Cabe señalar que la distancia euclídea sobre datos estandarizados, si bien elimina el efecto de las unidades de medida, no tiene en cuenta la correlación existente entre las variables. La distancia de Mahalanobis constituiría una alternativa más adecuada en presencia de correlación lineal entre variables, ya que incorpora la estructura de covarianza en el cálculo de distancias. No obstante, dado que el algoritmo *k-means* opera internamente con distancia euclídea y no admite una métrica alternativa, los resultados deben interpretarse teniendo en cuenta esta limitación.

Dada la naturaleza estocástica del algoritmo (dependiente de la inicialización aleatoria de centroides), se ejecutan 25 inicializaciones independientes, conservando la solución que minimiza la inercia intragrupo.

Para determinar el número óptimo de *clusters* K , se emplea el método del codo [23], que evalúa conjuntamente dos criterios: la suma total de cuadrados intra-cluster (*Total Within-Cluster Sum of Squares*, WSS), que mide la compacidad interna de los grupos y debe minimizarse, y la suma de cuadrados entre grupos (*Between-Cluster Sum of Squares*, BSS), que cuantifica la separación entre *clusters* y debe maximizarse. El valor de K se selecciona en el punto donde la reducción marginal del WSS (o el incremento marginal del BSS) al añadir un *cluster* adicional deja de ser sustancial, formando visualmente un codo en la curva.

5.4.1 Clustering solo con potencia

Este primer análisis considera los perfiles de generación eléctrica, omitiendo la influencia directa de las variables meteorológicas. Este enfoque permite identificar comportamientos operativos intrínsecos del sistema y clasificar las jornadas según su rendimiento neto.




Figura 5.2: Representación de la suma de la variabilidad al cuadrado dentro de los grupos (WSS) y entre grupos (BSS) para la determinación del número óptimo de *clusters* en el análisis basado en la potencia generada.

La Figura 5.2 presenta los resultados del método del codo aplicado exclusivamente sobre la variable de potencia generada. A diferencia de los análisis anteriores, el punto de inflexión es notablemente más pronunciado: tanto el descenso acusado del WSS como la ganancia en el BSS convergen de forma casi completa en $K = 3$. La nitidez de este codo refleja que, al trabajar con una única variable continua, la segmentación en tres niveles de producción resulta especialmente clara, señalando este valor como el número óptimo de *clusters*.

- **Cluster 1 — Alta producción** (173 días): presenta la mayor potencia media (98,8 kW), acompañada de la mayor radiación solar (240 W/m²) y temperatura media (16,8 °C), junto con la humedad más reducida (74,5 %). La suma de cuadrados intra-cluster es de 23,49.
- **Cluster 2 — Producción intermedia** (128 días): registra una potencia media de 59,5 kW, con radiación moderada (107 W/m²), temperatura contenida (13,2 °C) y humedad ligeramente superior (77 %). La suma de cuadrados intra-cluster asciende a 12,76.
- **Cluster 3 — Baja producción** (128 días): agrupa los días de menor generación eléctrica (25,6 kW), con la radiación más reducida (45,2 W/m²) y la mayor humedad relativa (81,5 %). La temperatura media (13,3 °C) es prácticamente idéntica a la del *cluster 2*, lo que sugiere que en este grupo la limitación productiva responde principalmente a la escasa disponibilidad de recurso solar más que a condiciones térmicas adversas. La suma de cuadrados intra-cluster es de 12,89.

La varianza explicada por la partición asciende al 88,5 %, lo que refleja la elevada homogeneidad interna de los grupos cuando el *clustering* se realiza sobre una única variable.




Figura 5.3: Evolución temporal de la potencia media diaria segmentada por *clusters*.

La Figura 5.3 muestra una separación muy clara entre los tres niveles de producción a lo largo del período de estudio. El *cluster* 1 domina los meses centrales del año (abril–septiembre), coincidiendo con el período de mayor insolación. El *cluster* 2 aparece con mayor frecuencia en los períodos de transición estacional, mientras que el *cluster* 3 se concentra en los meses invernales. El *clusplot* no se incluye en este caso. Al disponer de una única variable, el proyectar los datos sobre las dos primeras componentes principales no tiene sentido: toda la variabilidad está recogida en una sola dimensión.

5.4.2 Clustering con todas las variables

Finalmente, se realiza una segmentación que considera simultáneamente las variables meteorológicas y la potencia generada. El objetivo es identificar perfiles operativos completos, donde la respuesta eléctrica de la planta se analiza en el contexto climático directo que la origina.




Figura 5.4: Representación de la suma de la variabilidad al cuadrado dentro de los grupos (WSS) y entre grupos (BSS) para la determinación del número óptimo de *clusters*.

La Figura 5.4 presenta los resultados del método del codo aplicado al conjunto de datos completo. La suma de cuadrados intra-cluster (WSS) experimenta un descenso pronunciado hasta $K = 3$, punto a partir del cual la reducción marginal se estabiliza de forma notable. De forma complementaria, la suma de cuadrados entre grupos (BSS) muestra un comportamiento simétrico, con una ganancia decreciente a partir del mismo valor. Aplicando la metodología considerando 3 grupos, se obtienen los siguientes resultados:

- **Cluster 1 — Alta producción** (174 días): presenta la mayor potencia media (95,4 kW) y radiación solar (242 W/m²), con temperaturas elevadas (17,5 °C), humedad reducida (72,9 %) y precipitación prácticamente nula (0,92 mm). Se asocia a días de alta insolación y presenta una variabilidad interna de 590,39.
- **Cluster 2 — Producción intermedia** (159 días): registra una potencia media de 53,1 kW y radiación moderada (86,8 W/m²). Destaca por la mayor presión atmosférica (1018 hPa) y menor velocidad del viento (6,24 km/h), vinculándose a situaciones anticiclónicas con nubosidad persistente. Su variabilidad interna (WSS) es de 511,92.
- **Cluster 3 — Baja producción** (96 días): presenta la menor potencia media (30,6 kW) y radiación (52,4 W/m²), junto con la mayor precipitación (13 mm), menor presión (1005 hPa) y mayor velocidad del viento (15,2 km/h), característico de episodios de inestabilidad atmosférica. Posee una variabilidad interna (WSS) de 532,45.

El cociente entre la varianza inter-cluster y la varianza total (BSS/TSS) asciende al 45,4 %, valor inferior al obtenido en los análisis anteriores, lo que es esperable al trabajar con siete variables de naturaleza heterogénea: la mayor complejidad del espacio dificulta una separación tan nítida entre grupos, pero a cambio la partición incorpora tanto la dimensión climática como la productiva.




Figura 5.5: Evolución temporal de la potencia media diaria segmentada por *clusters*.

La Figura 5.5 aporta la dimensión temporal al *clustering*. El *cluster* 1 corresponde a los meses centrales del año, coincidiendo con el período de mayor insolación. El *cluster* 2 aparece con mayor frecuencia en los períodos de transición estacional (primavera y otoño), aunque también se intercala en verano. El *cluster* 3 corresponde a los días entre noviembre y febrero, si bien su presencia esporádica en meses cálidos permite identificar episodios puntuales de inestabilidad atmosférica.

El *clusplot* de la Figura 5.6 representa los 429 días proyectados sobre las dos primeras componentes principales, que explican conjuntamente el 65,84 % de la variabilidad total.¹ Cada observación se identifica mediante su índice ordinal en el conjunto de datos, lo que permite localizar días concretos en el espacio proyectado. La partición en $K = 3$ *clusters* muestra una separación razonablemente clara entre los tres grupos, con solapamientos moderados en las zonas de frontera, lo que es esperable en datos de naturaleza continua. Los tres *clusters* quedan bien diferenciados a lo largo de la componente 1, que actúa como el eje principal de separación, mientras que la componente 2 aporta una discriminación adicional más limitada. La estructura visual confirma que la solución de tres *clusters* captura una partición coherente del espacio multivariante definido por las variables meteorológicas y de producción.

¹ Nótese que el porcentaje indicado corresponde a la proyección bidimensional empleada exclusivamente con fines de visualización, y no constituye una medida de la calidad del *clustering*.




Figura 5.6: Representación del clustering mediante las dos primeras componentes principales. Las elipses delimitan las fronteras de decisión para los tres grupos identificados.

Con el fin de evaluar la coherencia entre los dos análisis *clustering* realizados, se construyó una tabla de contingencia cruzando las asignaciones de los *clustering* A y B (véase Tabla 5.5). Los resultados muestran una alta concordancia en los días de producción alta y baja, siendo el *cluster* de producción media el que presenta mayor discrepancia entre métodos, lo que sugiere que en días de irradiación moderada la información meteorológica resulta determinante para la clasificación final.

Tabla 5.5: Tabla de contingencia entre el *clustering* A (meteorología y potencia) y el *clustering* B (solo potencia). La mayor dispersión en el *cluster* 2 refleja que los días de producción media son los más sensibles a la inclusión o exclusión de variables meteorológicas.

Clust. A \ Clust. B	1	2	3
1	149	25	0
2	23	80	56
3	1	23	72

5.5 Modelos de regresión

El conjunto de 429 días válidos se dividió en un conjunto de entrenamiento (80 %, 343 días) y uno de prueba (20 %, 86 días) mediante muestreo aleatorio simple, fijando una semilla para garantizar la reproducibilidad. Todo el proceso de ajuste, selección y validación cruzada se realizó sobre el conjunto de entrenamiento, reservando el de prueba para la evaluación final imparcial de cada modelo.

5.5.1 Regresión lineal múltiple

Como punto de partida se ajustó un modelo de regresión lineal múltiple, que sirve de referencia para evaluar la ganancia que aporten los modelos flexibles explorados posteriormente.

Análisis de correlaciones

Las correlaciones simples bivariantes son consistentes con las obtenidas en el análisis descriptivo del Capítulo 4 (4.5.3), por lo que no se reiteran aquí en detalle. Basta recordar que la radiación solar es la variable con mayor asociación lineal con la potencia ($r = 0,880$), seguida de precipitación y humedad con signo negativo.

Las correlaciones parciales (ver Figura A.3 del Anexo) confirman y matizan este diagnóstico. La correlación parcial entre radiación y potencia desciende a 0,741, manteniéndose como la más elevada pero revelando que una parte sustancial de su asociación simple se explica por la covariación con *Mes_cos* ($r = -0,835$ entre ambas), variable que recoge la componente estacional de la insolación. De forma más llamativa, la correlación parcial de temperatura con potencia cae de $-0,402$ a $-0,239$, invirtiendo su signo: una vez controlada la radiación y la estacionalidad, días más cálidos no implican mayor producción, sino ligeramente menor, lo que es coherente con el efecto perjudicial del calor sobre la eficiencia de los paneles fotovoltaicos. La presión, con una correlación parcial de apenas $-0,008$, desaparece prácticamente como predictor neto, anticipando que el proceso de selección de variables la descartará. Las variables trigonométricas presentan correlaciones parciales moderadas con la potencia (*Mes_cos* = 0,155; *Mes_sin* = $-0,116$), sugiriendo que la estacionalidad aporta información residual más allá de la recogida por la radiación.

Ajuste del modelo completo e inferencia

El modelo completo se ajustó sobre el conjunto de entrenamiento incluyendo las seis variables meteorológicas continuas, las dos variables trigonométricas *Mes_sin* y *Mes_cos*, y la variable binaria *Laborable*, estimando un total de 10 parámetros con 333 grados de libertad residuales.

$$\begin{aligned}
\widehat{\text{Pot_Med}} = & 87,5318 + 0,3342 \cdot \text{Rad_Media} - 1,5345 \cdot \text{Temp_Media} \\
& - 0,3810 \cdot \text{Hum_Rel} - 0,3031 \cdot \text{Precip} \\
& - 0,4320 \cdot \text{Viento_Vel} - 0,0128 \cdot \text{Presion} \\
& - 0,6992 \cdot \text{Laborable} - 3,1885 \cdot \text{Mes}_{\sin} + 6,3797 \cdot \text{Mes}_{\cos}
\end{aligned} \tag{5.1}$$

El F -test global resulta altamente significativo ($F = 191,2$; $p < 2,2 \cdot 10^{-16}$), explicando el 83,8 % de la variabilidad total ($R_{\text{aj}}^2 = 0,833$). Los contrastes de tipo II confirman que *Rad_Media* es el predictor dominante ($F = 404,37$), seguido de *Temp_Media* ($F = 20,39$), *Hum_Rel* ($F = 9,54$) y *Mes_cos* ($F = 8,04$). *Presion* ($p = 0,904$) y *Laborable* ($p = 0,643$) no resultan significativas y serán las primeras candidatas a eliminarse en el proceso de selección.

Diagnóstico de multicolinealidad

El diagnóstico de multicolinealidad se llevó a cabo mediante indicadores complementarios aplicados sobre las covariables continuas del modelo:

- **Factores de inflación de varianza (VIF):** Confirman un diagnóstico moderado, ya que ninguna covariable supera el umbral clásico de 10 ni el umbral específico del modelo ($1/(1 - R^2) = 6,17$). Los valores más elevados corresponden a *Rad_Media* ($\text{VIF} = 5,49$) y *Mes_cos* ($\text{VIF} = 5,46$), lo cual es coherente al recoger ambas la estacionalidad de la insolación. El resto de las variables presentan VIF inferiores a 4.
- **Índice de condicionamiento (IC):** Toma un valor de $\text{IC} = 5,44$. Este resultado se sitúa por debajo del umbral de 10 que delimita la multicolinealidad apreciable. Asimismo, los autovalores oscilan entre 0,095 y 2,804, descartando combinaciones lineales casi exactas.

En conjunto, los dos indicadores apuntan a una multicolinealidad leve que no compromete la estabilidad de las estimaciones ni la interpretación de los coeficientes.

Previamente al proceso de selección, se realizó un diagnóstico de linealidad sobre el modelo completo mediante gráficos de residuos frente a cada covariable y gráficos de componente más residuo (Figura 5.7). El panel correspondiente a *Temp_Media* es el que muestra la desviación más marcada de la curva loess respecto al ajuste lineal que sugiere una relación no lineal entre temperatura y potencia. El panel de *Rad_Media*, aunque presenta una relación fuerte y predominantemente lineal, muestra una ligera curvatura en los valores extremos de irradiancia, coherente con la respuesta física no lineal de los paneles fotovoltaicos. El resto de covariables no presentan desviaciones sistemáticas relevantes entre ambas líneas.




Figura 5.7: Gráficos de componente más residuo. La línea discontinua azul representa el ajuste lineal del modelo; la línea rosa el suavizado no paramétrico.

Selección del modelo

Los tres procedimientos secuenciales (*stepwise* bidireccional, *backward* y *forward*) convergieron al mismo modelo con $AIC = 2730,84$, eliminando *Presion* y *Laborable*, dos variables que el análisis previo ya anticipaba como no informativas. La búsqueda exhaustiva confirmó este resultado: tanto el R^2 ajustado ($R_{aj}^2 = 0,834$) como el estadístico C_p de Mallows alcanzan su valor óptimo con 7 predictores, coincidiendo con el modelo del `stepAIC`. El criterio BIC, que penaliza más la complejidad, señala un modelo más parsimonioso de 4 variables; sin embargo, dado que los criterios AIC, R_{aj}^2 y C_p son consistentes entre sí y que la diferencia de BIC entre los modelos de 4 y 7 variables es modesta, se opta por el modelo de 7 predictores como solución al encontrar equilibrio entre ajuste e interpretabilidad.

El modelo seleccionado (ver salida completa en Anexo A.4) queda definido como:

$$\begin{aligned}
 \widehat{Pot_Media} = & 74,2852 + 0,3336 \cdot Rad_Media + 6,357 \cdot Mes_{cos} \\
 & - 1,5181 \cdot Temp_Media - 0,3013 \cdot Precip \\
 & - 3,1499 \cdot Mes_{sin} - 0,3828 \cdot Hum_Rel \\
 & - 0,4278 \cdot Viento_Vel
 \end{aligned} \tag{5.2}$$

Verificación de supuestos

La validación de los supuestos del modelo lineal se llevó a cabo mediante los cuatro gráficos estándar de diagnóstico (Figura 5.8) y tres contrastes formales.




Figura 5.8: Gráficos de diagnóstico del modelo seleccionado: residuos frente a valores ajustados, QQ-plot de residuos estandarizados, Scale-Location e influencia (residuos vs leverage).

Los contrastes formales sobre los residuos del modelo seleccionado arrojan resultados mixtos. Por un lado, el test de Lilliefors no rechaza la hipótesis de normalidad ($D = 0,040$; $p = 0,194$), resultado coherente con el QQ-plot con intervalos de confianza (véase Figura A.5 del Anexo), donde la práctica totalidad de los puntos se mantiene dentro de la banda de confianza salvo las observaciones 92 y 315, que presentan residuos extremos en la cola inferior.

El test de rachas tampoco rechaza la independencia de los residuos ($z = 0,731$; $p = 0,465$), descartando autocorrelación sistemática. Por otro lado, el test de Breusch-Pagan rechaza la homocedasticidad ($BP = 28,374$; $df = 7$; $p < 0,001$): la dispersión de los residuos crece con

los valores ajustados, confirmando que el modelo predice con menor precisión los días de alta producción. Este resultado, coherente con la no linealidad detectada en *Rad_Media*, constituye la principal limitación del modelo lineal y motiva la exploración de modelos más flexibles.

Se identificaron 16 observaciones con distancia de Cook superior al umbral $4/n = 0,012$. Para evaluar si su presencia era la causa de la heterocedasticidad detectada, se reajustó el modelo excluyéndolas (véase Anexo A.5). El test de Breusch-Pagan sobre el modelo sin influyentes arroja $BP = 41,566$ ($p < 0,001$), valor superior al del modelo original ($BP = 28,374$), lo que indica que la heterocedasticidad es estructural y no un artefacto de dichas observaciones. Adicionalmente, las métricas en test son prácticamente idénticas en ambos modelos (RMSE 15,48 vs 15,44 kW; $R^2 = 0,823$), por lo que se opta por mantener las 16 observaciones.

Validación cruzada sobre el conjunto de entrenamiento

La capacidad predictiva del modelo seleccionado se evaluó mediante validación cruzada repetida de 5 pliegues con 10 repeticiones sobre el conjunto de entrenamiento.

Tabla 5.6: Métricas de validación cruzada (5-CV, 10 repeticiones).

Modelo	RMSE (kW)	R^2
Completo	12,92	0,831
Seleccionado	12,86	0,833

El modelo seleccionado obtiene mejores resultados en los tres criterios: un RMSE de 12,86 kW frente a 12,92 kW del modelo completo, un R^2 de validación cruzada de 0,833 frente a 0,831. Aunque las diferencias son modestas, su consistencia en ambos criterios confirma que la eliminación de *Presion* y *Laborable* no solo no perjudica la capacidad predictiva sino que la mejora ligeramente al reducir el sobreajuste. La evaluación definitiva sobre el conjunto de prueba se presenta en la sección siguiente.

Evaluación final sobre el conjunto de prueba

La evaluación definitiva del modelo seleccionado sobre el conjunto de prueba (86 días) se presenta junto con la del Random Forest en la Sección 5.5.3. El gráfico de observado frente a predicho (véase Figura A.4 del Anexo) muestra que el modelo captura bien la tendencia general, aunque con mayor dispersión en los días de alta producción, coherente con la heterocedasticidad detectada y con la no-linealidad de la relación entre radiación y potencia.

5.5.2 Modelos no lineales: Random Forest

Como complemento al modelo lineal, se ajustó un modelo de Random Forest sobre el mismo conjunto de entrenamiento y con las mismas variables predictoras, con el fin de evaluar la ganancia que aporta un método más flexible. La implementación empleada es el paquete *ranger* [66], una versión eficiente del algoritmo en C++ para R. El número de árboles se fijó en 500 y el hiperparámetro *mtry* (número de variables candidatas en cada división) se seleccionó mediante validación cruzada repetida de 5 pliegues (10 repeticiones). El valor óptimo resultó ser *mtry* = 5, con un RMSE de validación cruzada de 10,41 kW y $R^2 = 0,89$. El gráfico de importancia de variables (véase Figura A.6 del Anexo) confirma el papel dominante de *Rad_Media*, cuya importancia por impureza de nodos supera ampliamente al resto de predictores. La variable *Mes_cos* ocupa el segundo lugar, seguida de *Precip* y *Hum_Rel*. Este ranking es coherente con los resultados del RLM, donde *Rad_Media* también era el predictor dominante.

La evaluación sobre el conjunto de prueba (ver Figura A.7 del Anexo) muestra que los puntos se ajustan mejor a la bisectriz que en el caso del RLM, con menor dispersión en la zona de alta producción, lo que confirma que el Random Forest captura la no-linealidad de la relación entre radiación y potencia que el modelo lineal no podía recoger.

5.5.3 Comparativa de modelos

La Tabla 5.7 recoge las métricas de ambos modelos sobre el conjunto de prueba. El Random Forest mejora al RLM en los dos criterios: el RMSE se reduce un 28,1 % y el R^2 aumenta de 0,823 a 0,916. Esta ganancia es consecuencia directa de la capacidad del RF para capturar la no linealidad, limitación que el diagnóstico de supuestos del RLM anticipaba.

Tabla 5.7: Comparativa de métricas en el conjunto de prueba.

Modelo	RMSE (kW)	R^2
RLM seleccionado	15,48	0,823
Random Forest	11,13	0,916

Análisis funcional

EL análisis de datos funcionales (FDA) trata cada día de registro como una realización de una variable funcional $\mathcal{X} : [a, b] \rightarrow \mathbb{R}$, una función real definida sobre un intervalo continuo de tiempo. Frente al enfoque del Capítulo 5, donde cada día quedaba representado por su potencia media y otras variables escalares, el tratamiento funcional preserva la estructura intra-diaria completa: la forma del perfil de producción, la velocidad de arranque al amanecer, la asimetría entre la mañana y la tarde, o la irregularidad debida al paso de nubes son características que se pierden al agregar y que el FDA puede modelar directamente. El análisis se implementa con el paquete `fda.usc` [20], extensión del paquete `fda` [19], y se organiza en torno a las siguientes etapas: representación funcional, suavizado, detección de outliers, componentes principales funcionales y regresión funcional.

6.1 Representación funcional de los datos

Se han representado como curvas funcionales las seis variables empleadas en el Capítulo 5, lo que permite comparar los resultados de ambos capítulos sobre una base común.

Rejillas de discretización

La representación funcional requiere definir para cada variable una rejilla de puntos $\{t_1, \dots, t_m\} \subset [a, b]$ en la que las curvas son evaluadas.

Para la potencia y la radiación solar se utiliza la rejilla $[5:00, 20:20]$ con paso de 10 minutos, lo que produce $m = 93$ puntos de discretización por curva. Esta ventana se determinó a partir de los registros de producción real del periodo de estudio: el percentil 1 del inicio diario de producción es las 5:00 y el percentil 99 del fin es las 20:10, cubriendo así la totalidad de la producción posible en Ferrol a lo largo del año sin incluir las horas de oscuridad garantizada. Los intervalos fuera del periodo de generación se fijan a cero por corresponder a ausencia física de producción. En cambio, los huecos aislados dentro del periodo diurno se

tratan como valores faltantes y se regularizan mediante interpolación lineal en la etapa de integración temporal.

Para la temperatura, la humedad relativa, la velocidad del viento y la presión atmosférica se utiliza la rejilla $[0:00, 23:50]$ con el mismo paso de 10 minutos, resultando en $m = 144$ puntos por curva. Estas variables presentan variación nocturna con información meteorológica relevante, por lo que restringir su dominio a las horas de producción supondría una pérdida de información injustificada. Los huecos aislados en las series meteorológicas (inferiores al 5 % de los 144 puntos de un día) se rellenan mediante interpolación lineal.

Estructura del objeto funcional

Todos los objetos funcionales se agrupan en un único objeto de la clase `ldata`, compuesto por un *data frame* de metadatos escalares y seis objetos de la clase `fdata`, uno por variable. El *data frame* recoge para cada día los identificadores temporales (fecha, mes, día de la semana), los indicadores operativos (laborable o festivo) y los resúmenes escalares diarios (potencia media, radiación media, etc.) que servirán como variables de respuesta o de estratificación en los análisis posteriores.

El conjunto de días sobre el que se construye el `ldata` comprende los 432 días del periodo de estudio con datos operativos válidos, es decir, una vez excluidos los días con parada técnica detectada en el preprocesado, según el criterio descrito en la Sección 4.4.4. La Tabla 6.1 resume las características de cada objeto funcional resultante.

Tabla 6.1: Resumen de los objetos `fdata` que componen el `ldata_fv`.

Variable	Dominio	Puntos	Días
<i>Pot_Media</i>	[5:00, 20:20]	93	432
<i>Rad_Media</i>	[5:00, 20:20]	93	432
<i>Temp_Media</i>	[0:00, 23:50]	144	432
<i>Hum_Rel</i>	[0:00, 23:50]	144	432
<i>Viento_Vel</i>	[0:00, 23:50]	144	432
<i>Presion</i>	[0:00, 23:50]	144	432

Inspección visual de las curvas




Figura 6.1: Curvas funcionales diarias de las seis variables del `ldata_fv`, coloreadas por mes del año (azul = invierno, rojo = verano).

La potencia y la radiación presentan perfiles en forma de campana cuya anchura y altura aumentan en verano, cuando el día solar es más largo y la irradiancia mayor. La temperatura refleja con claridad tanto la estacionalidad como el ciclo diario, con mínimos en la madrugada y máximos a primeras horas de la tarde. La humedad relativa muestra una mayor variabilidad intra-diaria en verano, con descensos pronunciados durante las horas centrales del día. El viento es la variable más irregular, con oscilaciones rápidas a lo largo de todo el día independientemente de la estación, lo que pone de manifiesto la necesidad de un suavizado previo. Por último, la presión atmosférica presenta curvas suaves con escasa variación intra-diaria, aunque sí se aprecia variabilidad inter-diaria asociada al paso de sistemas de presión.

6.2 Suavizado de las curvas funcionales

Las curvas construidas en la Sección 6.1 representan los registros diezminutales tal como fueron recogidos por el sistema SCADA y la estación meteorológica. Antes de aplicar cualquier método funcional es conveniente obtener una representación suavizada que elimine el ruido de medición sin destruir la estructura relevante de la señal. Se emplean dos estrategias distintas según la naturaleza de cada variable.

Potencia y radiación solar

Las curvas de potencia y radiación solar están sujetas a una restricción física: sus valores son siempre no negativos. Un suavizado mediante base B-spline estándar produce artefactos de contorno negativos en los extremos del dominio, donde la señal transita bruscamente entre el valor cero (oscuridad) y valores positivos al amanecer y al atardecer. Para resolver este problema se emplea la función `smooth.pos`, que ajusta el modelo $\mathcal{X}(t) = \exp(W(t))$, donde $W(t)$ se representa en una base B-spline de $K = 15$ elementos con parámetro de penalización $\lambda = 0,1$ sobre la segunda derivada. Debe tenerse en cuenta que esta transformación garantiza positividad estricta, por lo que los ceros físicos se aproximan mediante valores muy próximos a cero.

Los valores $K = 15$ y $\lambda = 0,1$ se fijaron mediante inspección visual, comprobando que preservaban la forma diaria principal de la señal y evitaban oscilaciones espurias en los extremos del dominio. El proceso de suavizado permite corregir los picos bruscos por sombras momentáneas en días de alta producción, eliminar los valores negativos en producciones medias y capturar la estructura compleja de la señal en días de baja producción. Una comparación visual detallada entre las curvas originales y suavizadas para estos tres tipos de días representativos puede consultarse en la Figura A.8 del Anexo.

Variables meteorológicas

Para temperatura, humedad relativa, velocidad del viento y presión atmosférica no existe la restricción de positividad. Para estas variables se emplea una representación B-spline no penalizada, usando el número de bases como mecanismo principal de control de suavidad. Sin embargo, el mínimo exacto del GCV ($K_{\min}$) tiende a seleccionar un número elevado de bases, produciendo representaciones con poco suavizado efectivo. Para obtener modelos más parsimoniosos se aplica la regla de un error estándar (véase ecuación (2.24)): en lugar del $K_{\min}$ exacto, se selecciona el K más pequeño cuyo GCV se encuentra dentro de un error estándar del mínimo, privilegiando la parsimonia frente al ajuste exacto.

La Figura A.11 del Anexo muestra las curvas GCV frente al número de bases K para las cuatro variables meteorológicas, con el $K_{\min}$, el umbral $\text{GCV} + \text{SE}$ y el $K_{1\text{SE}}$ seleccionado marcados explícitamente. La velocidad del viento es la que más se beneficia del criterio 1-SE, reduciendo el número de bases de $K_{\min} = 48$ a $K_{1\text{SE}} = 23$. Por su parte, temperatura y presión, al presentar señales más complejas a lo largo de las 24 horas, requieren un mayor número de bases incluso bajo el criterio 1-SE. Los resultados numéricos detallados pueden consultarse en la Tabla A.6 del Anexo.

La Figura 6.2 muestra las seis variables tras el suavizado, coloreadas por mes del año. Las curvas de potencia y radiación presentan la forma de campana característica sin valores

negativos. El viento, la variable más irregular, muestra un perfil más suave que el original. Las variables temperatura, humedad y presión mantienen su estructura intra-diaria con un nivel de suavizado moderado.




Figura 6.2: Curvas funcionales diarias de las seis variables tras el suavizado, coloreadas por mes del año (azul = invierno, rojo = verano).

6.3 Medidas de profundidad y outliers funcionales

Una vez construidas las curvas funcionales, el siguiente paso consiste en ordenarlas mediante una medida de profundidad funcional. Esta medida tiene una doble utilidad en el análisis: por un lado, permite identificar la curva más central o representativa del conjunto y caracterizar la morfología típica de la instalación mediante la media recortada; por otro, sirve para la detección de outliers funcionales, es decir, aquellas curvas cuya morfología se aparta del comportamiento habitual.

6.3.1 Elección del método y conjunto de curvas

El análisis de profundidad se realiza sobre las curvas originales de potencia, es decir, sin aplicar el suavizado de la Sección 6.2, reservando las curvas suavizadas para el FPCA y la

regresión funcional de las secciones posteriores. Esta decisión responde a que el suavizado puede atenuar las irregularidades morfológicas de las curvas más periféricas, reduciendo artificialmente la sensibilidad de los métodos de detección.

La profundidad de Fraiman-Muniz (FM) es tomada como medida principal, en línea con Febrero et al. [67]. Esta elección tiene una doble utilidad: por un lado, permite obtener medidas de tendencia central funcionales (mediana ponderada y media recortada), que se analizan en la Sección 6.3.2; por otro, sirve de base para la detección formal de outliers mediante dos procedimientos complementarios basados en bootstrap: uno ponderado, más conservador, y otro basado en recorte (*trim*), más sensible. La comparación entre ambos permite evaluar la robustez de los resultados y caracterizar las formas de las curvas atípicas detectadas.

La profundidad modal se exploró como alternativa. Esta profundidad asigna a cada curva una puntuación proporcional al número de curvas de la muestra situadas dentro de un radio h (el ancho de banda) en la métrica del espacio funcional: cuanto más rodeada está una curva por sus vecinas, mayor es su profundidad. El parámetro h determina, por tanto, la granularidad de la ordenación. En nuestros datos, el valor automático proporcionado por `depth.mode` resultó excesivo para la escala de las potencias registradas (en torno a los 139 kW), haciendo que prácticamente todas las curvas cayeran dentro del radio de vecindad de cualquier otra y produciendo profundidades poco discriminantes. La exploración manual de valores alternativos tampoco generó resultados estables, por lo que se descartó esta profundidad en favor de la FM.

6.3.2 Mediana y media recortada funcional

La curva con mayor profundidad FM y por ende la más central del conjunto de 432 días ($D_{FM} = 0,7568$) corresponde al **6 de febrero de 2025**. El resultado es coherente con el hecho de que las curvas de invierno presentan una variabilidad reducida entre sí (menor amplitud y duración del período de producción), lo que se traduce en que una mayor proporción de ellas ocupe posiciones centrales cuando se consideran conjuntamente todas las estaciones. La Figura 6.3 muestra las curvas coloreadas por profundidad FM, con la mediana funcional destacada en negro y la media recortada al 25 % en azul discontinuo.

Conviene advertir que el parámetro *trim* interviene con significados distintos en cada contexto. En la media recortada, `trim = 0,25` indica que se descarta el 25 % de curvas más periféricas para obtener una estimación robusta de la tendencia central, siguiendo la definición original de las α -trimmed means funcionales [48]. En la detección de outliers, `trim=0,01` indica la proporción de curvas menos profundas que se eliminan de la muestra antes de generar las réplicas bootstrap suavizadas, con el propósito de evitar que los propios outliers contaminen el procedimiento de calibración del umbral. Ambos usos de *trim* responden, por tanto, al mismo principio de recorte por profundidad, aunque aplicado a objetivos distintos:

estimación de la tendencia central en un caso, y robustez del bootstrap en otro. El nivel de significación del contraste (α), que controla la tasa de falsos positivos, se fija siguiendo los valores de referencia propuestos en Febrero et al. [67].




Figura 6.3: Conjunto de las 432 curvas diarias de potencia coloreadas según su profundidad de Fraiman-Muniz.

6.3.3 Estratificación estacional

Antes de proceder a la detección estratificada, se aplicaron ambos procedimientos bootstrap sobre el conjunto completo de 432 curvas. Ninguno de los dos métodos detectó outliers en el análisis global. Este resultado no se interpreta como ausencia de anomalías, sino como consecuencia de la alta heterogeneidad estacional del conjunto: cuando curvas de regímenes tan distintos (invierno y verano) se analizan conjuntamente, las diferencias extremas entre estaciones absorben la variabilidad periférica que, dentro de cada grupo, sería identificable como atípica. La estratificación no persigue, por tanto, aumentar artificialmente la detección, sino hacer comparables curvas del mismo régimen estacional: invierno (diciembre–febrero), primavera (marzo–mayo), verano (junio–agosto) y otoño (septiembre–noviembre). Dentro de cada grupo se aplica de forma independiente la profundidad FM con los mismos procedimientos bootstrap, de modo que el umbral se calibra sobre curvas del mismo régimen. Como se recoge en la Tabla A.7, el grupo de invierno presenta un mayor número de curvas respecto al resto debido a que el período de estudio abarca dos inviernos completos.

Los resultados de la detección estratificada se resumen en la Tabla A.8. Primavera y otoño no presentaron ninguna curva atípica con $n_B = 200$ réplicas bootstrap, y nivel de significación $\alpha = 0.01$, siguiendo los valores de referencia propuestos en Febrero et al. [67]. En invierno se confirmaron dos outliers (**2026-02-23** y **2026-02-26**), ambos con profundidades FM muy bajas dentro de su grupo ($D_{FM} = 0,061$ y $0,070$ respectivamente). En verano se confirmó un outlier (**2025-07-27**, $D_{FM} = 0,180$). La inspección visual de las curvas outlier, recogida en la Figura 6.4, revela que los dos outliers de invierno presentan una amplitud acorde con el período estacional pero con caídas bruscas a cero en la franja de máxima producción (11:00–15:00), compatibles con desconexiones técnicas intermitentes del sistema. El outlier de verano responde a un patrón distinto: la producción es prácticamente nula durante la jornada, lo que apunta a una parada completa de la instalación. Resulta destacable que este día había sido identificado como atípico multivariante en el Capítulo 5 mediante el algoritmo LOF, al presentar una combinación de variables escalares inusual respecto a sus vecinos. Su detección por dos métodos completamente distintos refuerza la solidez del resultado.




Figura 6.4: Curvas diarias de potencia identificadas como outliers funcionales mediante análisis estratificado. Izquierda: outliers de invierno; Derecha: outlier de verano.

La inspección visual del panel de verano revela la presencia de otras curvas con caídas parciales de producción similares a las del outlier detectado. Un análisis cuantitativo confirma que 36 de las 78 curvas del grupo (46,2 %) presentan valores mínimos inferiores a 10 kW en la franja horaria de máxima irradiancia (10:00–15:00). Esta proporción explica por qué los procedimientos basados en profundidad no detectan estas curvas individualmente: al com-

partir un patrón de caída, su profundidad relativa dentro del grupo es mayor que la de una curva verdaderamente aislada. La curva del 2025-07-27 se distingue del resto por la severidad y duración de la interrupción, lo que la sitúa en el extremo de menor profundidad y permite su identificación como outlier.

6.4 Análisis de componentes principales funcional (FPCA)

Antes de aplicar el FPCA se eliminan los tres outliers funcionales confirmados en la Sección 6.3, trabajando sobre las 429 curvas suavizadas restantes. Esta decisión evita que días con comportamiento anómalo compatible con incidencias técnicas distorsionen las autofunciones estimadas, de forma análoga a como los outliers distorsionan los ejes principales en el PCA multivariante.

6.4.1 Selección del número de componentes

Para cada variable funcional se calcula la varianza explicada acumulada y se selecciona el número mínimo de componentes K que supere el umbral del 90 %. Este criterio está motivado por el resultado de Hall et al. [51], que establece que incluir autofunciones con autovalores pequeños incrementa la varianza del estimador $\hat{\beta}$ en regresión funcional de forma potencialmente arbitraria, sin reducir el sesgo de manera apreciable. Este umbral se adopta como criterio operativo de reducción dimensional, no como una regla óptima en sentido predictivo. Los resultados para las seis variables funcionales se recogen en la Tabla 6.2.

Tabla 6.2: Porcentaje de varianza explicada por componente para las seis variables funcionales.

Variable	PC1	PC2	PC3	PC4	PC5	Var. acum.
<i>Pot_Media</i>	70,57	12,67	7,85	—	—	91,09 %
<i>Temp_Media</i>	85,12	9,09	—	—	—	94,21 %
<i>Rad_Media</i>	79,35	7,69	4,49	—	—	91,53 %
<i>Hum_Rel</i>	52,49	20,29	11,17	5,16	2,86	91,97 %
<i>Viento_Vel</i>	62,96	15,36	6,95	3,19	2,18	90,64 %
<i>Presion</i>	95,20	—	—	—	—	95,20 %

Destaca la concentración extrema de la presión atmosférica en su primera componente (95,20 %), coherente con la regularidad del ciclo semidiurno. En el extremo opuesto, la humedad es la variable más dispersa y requiere cinco componentes para superar el umbral, lo que refleja la alta variabilidad de las condiciones atmosféricas en la costa gallega. La temperatura,

por su parte, presenta la mayor concentración relativa entre las variables con ciclo diurno apreciable: una sola componente captura el 85,12 % de su variabilidad, lo que indica que la diferencia principal entre días es simplemente si el día es más o menos cálido.

Conviene advertir que los porcentajes de varianza del PCA clásico y del FPCA no son directamente comparables, puesto que ambos métodos descomponen estructuras distintas: el primero resume la covariación entre variables escalares diarias, mientras que el FPCA describe la variabilidad temporal interna de cada variable funcional por separado. En potencia, radiación y temperatura la primera componente domina claramente, indicando que el principal modo de variación entre días es un cambio de nivel global de la curva. En humedad y viento, la varianza se reparte entre cinco componentes, reflejo de una mayor irregularidad intra-diaria.

6.4.2 Autofunciones e interpretación

Potencia

Las dos primeras autofunciones de potencia se muestran en la Figura 6.5. La primera autofunción presenta signo positivo en todo el intervalo de producción, con un perfil bimodal: un primer máximo relativo hacia las 12:00 y el máximo absoluto a las 15:00, coincidiendo con el mediodía solar en Ferrol. Captura el nivel global de producción diaria, con una correlación de $r = 0,96$ entre su score y la potencia media diaria.




Figura 6.5: Primera y segunda autofunción del FPCA sobre las curvas de potencia suavizadas.

Scores positivos elevados corresponden a curvas sistemáticamente por encima de la media funcional (días de alta irradiancia); scores negativos, a curvas por debajo (días nublados o de baja producción). Conviene advertir que scores próximos a cero no deben identificarse con baja producción: representan perfiles próximos a la curva media funcional, que en esta instalación corresponde a una producción media de aproximadamente 65 kW. La Figura A.9 del Anexo verifica esta interpretación: la potencia media diaria es de 23,4 kW para el grupo Q1, 65,6 kW para Q2–Q3 y 105,1 kW para Q4.

La segunda autofunción es de signo cambiante: positivo durante la mañana (hasta las 13:00) y negativo en la franja de máxima producción (13:00–18:00), con mínimo hacia las 15:00. Captura la asimetría temporal del perfil: scores positivos corresponden a días con producción concentrada en la mañana (entrada de nubosidad por la tarde), mientras que scores negativos caracterizan días con producción sostenida o desplazada hacia las horas centrales.

Temperatura

Las autofunciones de temperatura se muestran en la Figura 6.6. La primera presenta valores positivos en todo el dominio, con máximo absoluto en torno a las 10:00 y valores algo menores en las horas nocturnas. Captura el nivel térmico global del día: scores positivos elevados corresponden a días cálidos y scores negativos a días fríos, como verifica la Figura A.10. El 85,12 % de varianza explicada refleja que la principal diferencia entre jornadas es simplemente su nivel térmico.




Figura 6.6: Primera y segunda autofunción del FPCA sobre las curvas de temperatura suavizadas.

La segunda autofunción es de signo cambiante: positiva durante las primeras horas (0:00–8:00), con máximo hacia las 5:00–6:00, y negativa en el intervalo central (10:00–20:00), con mínimo en torno a las 14:00. Opone las horas de madrugada frente al mediodía: scores positivos corresponden a días con temperaturas nocturnas relativamente elevadas pero moderación diurna, mientras que scores negativos caracterizan días con madrugadas frías y calentamiento progresivo hacia el mediodía.

El número de componentes retenidas para cada variable, que determinará la dimensión del espacio de predictores en la Sección 6.5, queda fijado en:

$$K_{\text{pot}} = 3, \quad K_{\text{temp}} = 2, \quad K_{\text{rad}} = 3, \quad K_{\text{hum}} = 5, \quad K_{\text{viento}} = 5, \quad K_{\text{presion}} = 1. \quad (6.1)$$

6.5 Regresión funcional

Todos los modelos se ajustan sobre los 427 días resultantes de la intersección entre las 429 curvas funcionales del análisis anterior y los 429 días del conjunto escalar del Capítulo 5. La diferencia se debe a que cada capítulo excluye un conjunto distinto de tres días atípicos: el Capítulo 5 elimina los tres outliers multivariantes detectados por LOF (2025-01-03, 2025-02-24 y 2025-07-27), mientras que este capítulo elimina los tres outliers funcionales confirmados en la Sección 6.3 (2026-02-23, 2026-02-26 y 2025-07-27). Como 2025-07-27 es común a ambos conjuntos, la intersección excluye cinco fechas únicas: $432 - 5 = 427$ días. Esta restricción garantiza que el modelo funcional seleccionado y el modelo escalar de referencia M0 se evalúan sobre exactamente el mismo conjunto de prueba, haciendo la comparación directamente válida. La muestra se divide en entrenamiento (80 %, $n = 342$) y prueba (20 %, $n = 85$).

6.5.1 Estrategia de modelización

La estrategia seguida es jerárquica: se parte de un modelo de referencia escalar que utiliza únicamente las medias diarias de las variables meteorológicas, y se avanza hacia modelos funcionales de complejidad creciente. Se ajustan tres familias de modelos:

1. **M1/M2 — Modelos funcionales simples.** Una única covariable funcional (curva de radiación o de temperatura) se incluye como predictor. Se consideran dos variantes de ajuste: en la primera (a), el número de componentes principales K se fija según el criterio de varianza acumulada descrito en la Sección 6.4. En la segunda variante (b), tanto K como el parámetro de penalización λ se seleccionan conjuntamente mediante validación cruzada, permitiendo que el propio proceso de ajuste determine el grado óptimo de regularización en función del error de predicción.

2. **M3 — Modelo funcional múltiple.** Combina las curvas de radiación, temperatura y humedad como covariables funcionales.
3. **M4 — Modelo funcional extendido.** Amplía M3 incorporando las curvas de viento y presión, y la media diaria de radiación como covariable escalar adicional.

El modelo seleccionado es aquel cuya estructura se determina exclusivamente sobre el conjunto de entrenamiento, combinando validación cruzada y parsimonia; el conjunto de prueba se reserva únicamente para la evaluación final de los modelos seleccionados y no interviene en ninguna decisión de modelización.



6.5.2 Modelos funcionales simples

Como primer paso hacia el enfoque funcional se ajustan modelos lineales escalar-funcionales [50, 52], en los que la respuesta es escalar (potencia media diaria) y el predictor funcional se representa en una base de componentes principales funcionales.

Radiación solar

El modelo M1a utiliza las tres primeras componentes principales de la curva de radiación, retenidas en la Sección 6.4. Evaluado sobre el conjunto de prueba, obtiene un $R^2 = 0,881$ y un RMSE = 12,17 kW. La función parámetro estimada $\hat{\beta}(t)$ (Figura 6.7) presenta una forma de campana unimodal centrada en torno a las 13 h, con valores próximos a cero antes de las 8 h y después de las 18 h, lo que indica que la radiación en las horas centrales del día es la que mayor peso tiene en la predicción de la potencia media diaria.

El modelo M2a, con selección automática de componentes y parámetro de penalización mediante validación cruzada, selecciona cinco componentes (PC1, PC2, PC3, PC5, PC6) con $\lambda = 10^4$. Aunque mejora el ajuste en train ($R^2 = 0,900$, RMSE = 10,03 kW), su capacidad predictiva sobre el conjunto de prueba cae drásticamente hasta $R^2 = 0,276$ y RMSE = 30,05 kW, lo que revela un sobreajuste severo. La función parámetro estimada (Figura 6.8) presenta oscilaciones de signo cambiante y una caída pronunciada al final del dominio que carece de interpretación física, síntoma de inestabilidad del modelo. La exploración de un rango ampliado de valores de penalización ($\lambda \in \{0, 10^{-4}, \dots, 10^2\}$) no modifica la selección de componentes ni mejora la capacidad predictiva en test, lo que confirma que el sobreajuste tiene origen estructural en la selección de componentes no contiguas y no puede corregirse mediante regularización. Por tanto, M1a se considera el modelo funcional simple más adecuado para la curva de radiación.

Figura 6.7: $\hat{\beta}(t)$ del modelo M1a.Figura 6.8: $\hat{\beta}(t)$ del modelo M2a.

Temperatura

Los modelos sobre la curva de temperatura obtienen resultados notablemente inferiores a los de radiación. M1b, con dos componentes principales fijas, presenta $R^2 = 0,373$ y RMSE = 27,97 kW sobre el conjunto de prueba. M2b, con selección automática de cinco componentes y $\lambda = 0,01$, mejora ligeramente hasta $R^2 = 0,432$ y RMSE = 26,62 kW, sin presentar el sobreajuste severo observado en M2a. En ambos casos la temperatura en solitario es un predictor débil de la potencia media diaria, lo que es coherente con el análisis de correlaciones del Capítulo 5: la temperatura está correlada con la potencia de forma indirecta, a través de su asociación con la estacionalidad. Su valor predictivo reside en su papel como covariable complementaria en los modelos múltiples de la sección siguiente.

6.5.3 Modelo funcional múltiple

La incorporación simultánea de varias covariables funcionales permite al modelo capturar la contribución diferenciada de cada variable meteorológica a lo largo del día. Se ajustan dos modelos: M3, que combina las curvas de radiación, temperatura y humedad, y M4, que extiende M3 añadiendo las curvas de viento y presión junto con la media diaria de radiación como covariable escalar.

M3: radiación, temperatura y humedad

El modelo M3 combina las curvas funcionales de radiación, temperatura y humedad relativa como covariables, utilizando los valores de K fijados en la Sección 6.4 mediante el criterio de varianza acumulada. Al haberse determinado la estructura del modelo exclusivamente sobre el conjunto de entrenamiento, no se aplica penalización adicional; la diferencia entre train y test ($\Delta\text{RMSE} = 2,25$ kW) confirma que el modelo generaliza correctamente sin necesidad de

regularización extra. Sobre el conjunto de prueba obtiene $R^2 = 0,902$ y $\text{RMSE} = 11,08$ kW, mejorando claramente a M1a en capacidad predictiva.

Las funciones parámetro estimadas (Figura 6.9) deben interpretarse conjuntamente y de forma condicional, dado que las covariables funcionales están correlacionadas entre sí. $\hat{\beta}_{\text{rad}}(t)$ mantiene la campana unimodal centrada en las 13 h ya observada en M1a. $\hat{\beta}_{\text{temp}}(t)$ presenta signo negativo en prácticamente todo el dominio, lo que refleja el efecto condicional de la temperatura una vez descontada la radiación; su interpretación no es directa debido a la colinealidad entre ambas variables. $\hat{\beta}_{\text{hum}}(t)$ presenta signo cambiante con valores negativos en torno a las 10 h y las 16 h, coherente con el efecto atenuador de la humedad alta sobre la irradiancia efectiva.




Figura 6.9: Funciones parámetro estimadas $\hat{\beta}(t)$ del modelo M3 para las covariables de radiación (izquierda), temperatura (centro) y humedad relativa (derecha).

M4: modelo extendido

El modelo M4 amplía M3 incorporando las curvas de viento y presión atmosférica, y la media diaria de radiación como covariable escalar adicional. Sobre el conjunto de prueba alcanza $R^2 = 0,906$ y $\text{RMSE} = 10,84$ kW, una mejora marginal respecto a M3 (0,24 kW en RMSE) a costa de añadir 7 parámetros adicionales. El resumen del modelo muestra que ninguna de las componentes de viento resulta significativa, ni tampoco la covariable escalar Rad_Media ($p = 0,152$). La única variable incorporada respecto a M3 con efecto significativo es la primera componente de presión atmosférica ($p = 0,036$), aunque su contribución a la reducción del

RMSE en test es marginal. Las funciones parámetro de viento (véase Figura A.12 del Anexo) no muestran un efecto funcional claro ni interpretable físicamente, lo que refuerza su no significación. Dado que seis de los siete predictores incorporados no resultan significativos y la mejora predictiva es mínima, M3 se selecciona como modelo final por parsimonia, sin haber empleado el conjunto de prueba como criterio de selección.

6.5.4 Diagnóstico del modelo final

Se verifican los supuestos del modelo M3 mediante diagnóstico gráfico en la (Figura A.13) del Anexo, así como contrastes formales sobre los residuos del ajuste en train.

El gráfico de valores ajustados frente a observados muestra una alineación próxima a la bisectriz en todo el rango de producción, sin sesgos sistemáticos. El gráfico de residuos frente a valores ajustados no revela ningún patrón estructural, con dispersión aproximadamente homogénea. El QQ-plot presenta una distribución muy próxima a la normal, con ligeras desviaciones únicamente en las colas.

El test de Shapiro-Wilk rechaza la normalidad estricta ($W = 0,985$, $p = 0,002$), si bien con muestras de tamaño $n = 342$ este contraste es muy sensible a desviaciones menores en las colas que no comprometen la validez práctica del modelo [33]. La homocedasticidad no se rechaza mediante el contraste de Breusch-Pagan ($p = 0,192$), y el test de rachas confirma la independencia de los residuos ($z = -1,48$, $p = 0,139$). En conjunto, el diagnóstico no revela incumplimientos graves de los supuestos residuales y respalda la utilización del modelo con fines descriptivos y predictivos, aunque la normalidad estricta es rechazada.

Conclusiones y trabajo futuro

Este capítulo cierra la memoria recapitulando la situación final del trabajo a la luz de los resultados obtenidos, proponiendo las líneas de continuación y relacionándolo con las competencias del grado.

7.1 Situación final del trabajo

El objetivo general (modelar y predecir la generación fotovoltaica de la instalación del taller de módulos y reparaciones de Navantia Ferrol mediante análisis multivariante y funcional) se ha alcanzado por completo.

La fase de fuentes de datos y estudio descriptivo realizada en el Capítulo 4 integró los más de dos millones de registros asíncronos del SCADA con la información meteorológica de MeteoGalicia, tras corregir el desfase horario de esta última y regularizar ambas fuentes a una rejilla diezminutal. Depurados los días con anomalías operativas, se obtuvo un conjunto de 432 días sobre el que el análisis exploratorio ya señaló a la radiación como predictor dominante y determinó el carácter atlántico del emplazamiento.

El análisis multivariante del Capítulo 5 confirmó ese diagnóstico: el PCA sobre los inversores concentró el 99,33 % de la varianza en una única componente en la que cada uno de los inversores influía de forma similar, justificando el uso de la potencia media como variable de producción. En la fase predictiva, el Random Forest ($R^2_{\text{test}} = 0,911$; RMSE = 10,54 kW, reevaluado sobre el test común de 85 días, véase nota de la Tabla 7.1) superó a la regresión lineal ($R^2_{\text{test}} = 0,812$) al capturar la no linealidad que su propio diagnóstico anticipaba.

El análisis funcional (Capítulo 6) trató cada jornada como una curva continua, lo que permitió suavizar con restricción de positividad, detectar tres días atípicos de origen técnico mediante profundidad de Fraiman–Muniz, extraer los principales modos de variación con FPCA y, finalmente, ajustar el modelo de regresión funcional M3 (radiación, temperatura y humedad), que obtuvo $R^2_{\text{test}} = 0,902$ y RMSE = 11,08 kW.

La detección multivariante y la funcional resultaron además complementarias: LOF identificó días con combinaciones escalares inusuales, mientras que la profundidad funcional detectó alteraciones en la forma intradiaria. Solo el 2025-07-27 fue señalado por ambos procedimientos, reforzando especialmente su carácter anómalo.

La Tabla 7.1 recoge las métricas completas de todos los modelos evaluados sobre el mismo conjunto de prueba ($n = 85$), permitiendo una comparación directa entre enfoques.

Tabla 7.1: Comparación de todos los modelos sobre conjunto de entrenamiento y de prueba. M0 es el modelo escalar seleccionado del Capítulo 5; M3 es el modelo funcional seleccionado como modelo final. Las métricas de M0 y RF corresponden a su reevaluación sobre el conjunto de prueba común de 85 días, por lo que difieren ligeramente de las reportadas en el Capítulo 5.

Modelo	Descripción	R^2 train	RMSE train (kW)	R^2 test	RMSE test (kW)
M0	Lineal múltiple (7 pred.)	0,838	12,62	0,812	15,30
M1a	Funcional: radiación, $K=3$	0,877	11,13	0,881	12,17
M2a	Funcional: radiación, CV	0,900	10,03	0,276	30,05
M1b	Funcional: temperatura, $K=2$	0,464	23,20	0,373	27,97
M2b	Funcional: temperatura, CV	0,581	20,52	0,432	26,62
M3	Funcional múltiple	0,923	8,83	0,902	11,08
M4	Funcional extendido	0,925	8,69	0,906	10,84
RF	Random Forest	0,890	10,41	0,911	10,54

El resultado más relevante surge de comparar ambos enfoques: el Random Forest obtiene la menor pérdida predictiva en el conjunto de prueba (RMSE = 10,54 kW), mientras que el modelo funcional M3 alcanza un rendimiento muy próximo (RMSE = 11,08) con la ventaja de proporcionar una interpretación explícita a través de las funciones parámetro estimadas $\hat{\beta}(t)$. El modelo M4 mejora solo marginalmente a M3 (0,24 kW en RMSE) a costa de una mayor complejidad y sin aportar una interpretación clara de las variables añadidas debido a la colinealidad entre covariables funcionales. Por ello, M3 se adopta como modelo funcional final, mientras que el Random Forest se mantiene como referencia predictiva. El análisis funcional no sustituye, por tanto, al multivariante, sino que lo complementa, proporcionando capacidad predictiva e interpretabilidad.

7.2 Trabajo futuro

El estudio admite continuación en varias direcciones, algunas sugeridas por las propias limitaciones detectadas:

- Calibración de la profundidad modal mediante selección óptima del ancho de banda h por validación cruzada, combinando FDA y estimación no paramétrica de la densidad.

- Extensión de los modelos funcionales incorporando selección de variables mediante correlación de distancias, que permitiría identificar de forma no paramétrica qué tramos temporales de cada covariable funcional son más relevantes para la predicción.
- Extensión de la comparativa predictiva a otros modelos de aprendizaje automático como *gradient boosting* (XGBoost, LightGBM) o máquinas de vectores soporte, con el fin de determinar si existen alternativas más precisas.
- Predicción operativa a uno o varios días vista, alimentando los modelos con previsiones meteorológicas (MeteoGalicia, AEMET) en lugar de valores observados, y evaluando cómo se propaga la incertidumbre del pronóstico meteorológico a la estimación de producción.
- Modelos de respuesta funcional (función-sobre-función) que predigan la curva de potencia completa, no solo su media diaria.
- Ampliación temporal del estudio incorporando los registros futuros de la instalación, lo que permitiría cubrir ciclos anuales completos, estabilizar la componente estacional y detectar tendencias de degradación de los paneles.
- Replicación de la metodología en otras instalaciones fotovoltaicas de Navantia, con el fin de evaluar su capacidad de generalización y sentar las bases de un sistema de monitorización y predicción escalable.

7.3 Relación con el grado

El Trabajo de Fin de Grado refleja las competencias adquiridas a lo largo del Grado en Ciencia e Ingeniería de Datos. La materia de Modelos de Regresión, de 2º curso, es la referencia directa de lo desarrollado en el apartado de regresión lineal múltiple: procesos como la selección de variables por stepwise, el diagnóstico de multicolinealidad o el análisis de influencia reproducen los contenidos de la asignatura. La serie de asignaturas de Aprendizaje Automático proporcionó los fundamentos del Random Forest, la validación cruzada y el control del sobreajuste, directamente aplicados en la fase predictiva. Por su parte, Modelización Estadística de Datos de Alta Dimensión, de 2º curso, sustentó las técnicas de reducción de dimensionalidad, representación y *clustering* del análisis multivariante. Finalmente, la asignatura Análisis Estadístico de Datos Complejos, de 4º curso, es la base directa del Capítulo 6: la representación de cada jornada como objeto funcional, el suavizado, la detección de *outliers* mediante profundidad de Frayman-Muniz, el FPCA y los modelos de regresión funcional reproducen los contenidos de dicha materia.

Más allá de las técnicas concretas, el grado ha proporcionado la autonomía y capacidad de abordar un problema real mediante la formulación de hipótesis, el análisis de resultados y la toma de decisiones justificadas.

Apéndices

Apéndice A

Material adicional

A.1 Instalación y datos SCADA



Figura A.1: Inversores fotovoltaicos KACO BLUEPLANET 100 NX3 instalados en la planta.
[Fuente: Documento interno]

Tabla A.1: Registros asíncronos del SCADA correspondientes al 10 de marzo de 2025.

Timestamp original	Inv1 (kW)	Inv2 (kW)	Inv3 (kW)
<i>Intervalo a regularizar: 12:30:00</i>			
12:30:02.905	15,50679	–	–
12:30:10.905	–	14,41002	–
12:30:13.907	–	–	16,81866
12:30:18.897	15,19428	–	–
12:30:26.897	–	14,11174	–
12:30:28.897	–	–	16,48191

A.2 Análisis multivariante




Figura A.2: Densidad de probabilidad de los scores LOF para la detección de outliers.

Tabla A.3: Autovalores de la matriz de productos escalares centrados y bondad de ajuste acumulada para cada dimensión (MDS sobre variables).

i	λ_i	GOF (i)
1	2,653	0,433
2	1,706	0,711
3	0,739	0,832
4	0,600	0,930
5	0,341	0,986
6	0,089	1
7	0	1




Figura A.3: Matriz de correlaciones parciales de las variables continuas del modelo de regresión. Valores próximos a ± 1 indican dependencia lineal fuerte una vez controlado el efecto del resto de variables.

Tabla A.4: Coeficientes estimados del modelo de regresión lineal múltiple seleccionado. Todos los predictores son significativos al nivel del 5 %.

Variable	Estimación	Error típico	<i>t</i>	p-valor
(Intercept)	74,285	12,650	5,872	<0,001 ***
<i>Rad_Media</i>	0,334	0,016	21,076	<0,001 ***
<i>Mes_cos</i>	6,357	2,179	2,917	0,004 **
<i>Temp_Media</i>	-1,518	0,337	-4,509	<0,001 ***
<i>Precip</i>	-0,301	0,113	-2,674	0,008 **
<i>Mes_sin</i>	-3,150	1,470	-2,143	0,033 *
<i>Hum_Rel</i>	-0,383	0,121	-3,161	0,002 **
<i>Viento_Vel</i>	-0,428	0,166	-2,571	0,011 *




Figura A.4: Potencia observada frente a potencia predicha por el modelo de regresión lineal múltiple seleccionado sobre el conjunto de prueba. La línea discontinua roja representa la predicción perfecta.




Figura A.5: QQ-plot de los residuos del modelo seleccionado con banda de confianza al 95 %.

Tabla A.5: Coeficientes estimados del modelo RLM seleccionado excluyendo las 16 observaciones con distancia de Cook superior a $4/n$. Nótese que *Mes_sin* pierde la significación individual al 5 % respecto al modelo original.

Variable	Estimación	Error típico	<i>t</i>	<i>p</i> -valor
(Intercept)	68,165	10,776	6,325	<0,001 ***
<i>Rad_Media</i>	0,360	0,014	26,471	<0,001 ***
<i>Mes_cos</i>	9,771	1,850	5,282	<0,001 ***
<i>Temp_Media</i>	-0,884	0,289	-3,062	0,002 **
<i>Precip</i>	-0,252	0,106	-2,378	0,018 *
<i>Hum_Rel</i>	-0,446	0,102	-4,371	<0,001 ***
<i>Viento_Vel</i>	-0,631	0,141	-4,469	<0,001 ***




Figura A.6: Importancia de variables del modelo Random Forest.




Figura A.7: Potencia observada frente a potencia predicha por el Random Forest sobre el conjunto de prueba.

A.3 Análisis funcional

Tabla A.6: Número de bases B-spline seleccionadas por el criterio GCV ($K_{\min}$) y por la regla de un error estándar (K_{1SE}). El ratio se calcula como K_{1SE} dividido entre el número de puntos de discretización (144).

Variable	Puntos	$K_{\min}$	K_{1SE}	Ratio
Temperatura	144	86	61	0,42
Humedad relativa	144	75	53	0,37
Viento	144	48	23	0,16
Presión	144	89	44	0,31




Figura A.8: Comparación entre la curva original (gris) y la suavizada con `smooth.pos` para tres días representativos de la curva de potencia: alta producción (rojo), producción media (naranja) y baja producción (azul).

Tabla A.7: Distribución de las 432 curvas diarias de potencia por estación meteorológica, sobre el conjunto de datos completo previo a la detección de outliers.

Estación	Curvas	Pot. media (kW)	SD (kW)
Invierno (Dic–Feb)	157	43,9	25,0
Primavera (Mar–May)	89	86,2	30,8
Verano (Jun–Ago)	78	87,0	23,2
Otoño (Sep–Nov)	108	61,6	29,2




Figura A.9: Curvas de potencia agrupadas por cuartil del score de la FPC1.




Figura A.10: Curvas de temperatura agrupadas por cuartil del score de la FPC1.

Tabla A.8: Outliers funcionales confirmados por el análisis estratificado. La profundidad FM se calcula dentro del grupo estacional correspondiente.

Estación	Fecha	Prof. FM (grupo)	Métodos
Invierno	2026-02-23	0,0614	pond $\cap$ trim
Invierno	2026-02-26	0,0697	pond $\cap$ trim
Verano	2025-07-27	0,1795	pond $\cap$ trim




Figura A.11: Curvas GCV frente al número de bases K para las cuatro variables meteorológicas. Línea roja: $K_{\min}$ (mínimo exacto del GCV). Línea verde: K_{1SE} seleccionado por la regla de un error estándar. Línea naranja: umbral $\widehat{GCV}(K_{\min}) + \widehat{SE}$.




Figura A.12: Funciones parámetro estimadas $\hat{\beta}(t)$ del modelo M4 para las covariables de radiación, temperatura, humedad relativa, velocidad del viento y presión atmosférica.




Figura A.13: Diagnóstico de residuos del modelo final M3: valores ajustados frente a observados (izquierda), residuos frente a valores ajustados (centro) y QQ-plot de los residuos (derecha).

Bibliografía

- [1] D. Roca Vilariño, “Proyecto modernización en entorno 4.0 de la sub-estación eléctrica 132 kV/15 kV Navantia Ferrol,” <https://www.ica.es/proyecto-modernizacion-en-entorno-4-0-de-la-subestacion-electrica-132-kv-15-kv-navantia-ferrol/>, 2022, asociación/Colegio Nacional de Ingenieros ICAI, recuperado el 20 de junio de 2026.
- [2] Diario de Ferrol, “Los paneles solares instalados en Navantia permitirán cubrir el 10% de su consumo eléctrico,” <https://www.diariodeferrol.com/articulo/ferrol/paneles-solares-instalados-navantia-permitiran-cubrir-10-consumo-electrico-5040360>, 2024, recuperado el 20 de junio 2026.
- [3] Enerclub, “La energía en Galicia: retos y oportunidades de la transición energética,” <https://www.enerclub.es/actividades/egalicia/>, 2023, recuperado el 21 de junio de 2026.
- [4] Instituto Energético de Galicia (INEGA), “Balance energético de Galicia 2024,” <https://www.inega.gal/es/publicaciones/energia-en-galicia/balance-energetico-de-galicia>, 2025, recuperado el 21 de junio de 2026.
- [5] Xunta de Galicia, “Agenda energética de Galicia 2030 (AxEGA30),” <https://www.xunta.gal/es/hemeroteca/-/nova/158930/agenda-energetica-galicia-2030-acercara-nuevas-oportunidades-para-toda-industria>, 2022, recuperado el 21 de junio de 2026.
- [6] Ministerio para la Transición Ecológica y el Reto Demográfico (MITECO), “Plan Nacional Integrado de Energía y Clima. actualización 2023-2030,” <https://www.miteco.gob.es/es/energia/estrategia-normativa/pniec-23-30.html>, 2024, recuperado el 20 de junio de 2026.
- [7] Consejo de la Unión Europea, “El Pacto Verde Europeo,” <https://www.consilium.europa.eu/es/policies/european-green-deal/>, 2026, recuperado el 2 de marzo de 2026.

- [8] Comisión Europea, “«Fit for 55»: cumplir el objetivo climático de la UE para 2030 en camino hacia la neutralidad climática,” <https://eur-lex.europa.eu/legal-content/ES/TXT/?uri=CELEX%3A52021DC0550>, 2021, recuperado el 26 de febrero de 2026.
- [9] Navantia, “Medio ambiente y sostenibilidad: nuestro compromiso net-zero,” <https://www.navantia.es/es/sostenibilidad/medio-ambiente/>, 2024, recuperado el 26 de febrero de 2026.
- [10] PV Magazine España, “Navantia adjudica la segunda fase de su proyecto FV de 6 MW en el puerto de Ferrol,” <https://www.pv-magazine.es/2025/02/12/navantia-adjudica-la-segunda-fase-de-su-proyecto-fv-de-6-mw-en-el-puerto-de-ferrol/>, 2025, recuperado el 15 de junio de 2026.
- [11] PV Magazine España, “Navantia licita un proyecto de autoconsumo de 1,29 MW en su factoría de Ferrol,” <https://www.pv-magazine.es/2026/05/11/navantia-licita-un-proyecto-de-autoconsumo-de-129-mw-en-su-factoria-de-ferrol/>, 2026, recuperado el 15 de junio de 2026.
- [12] Fundació Centre per a la Ciència i la Recerca Energètica (FCIRCE), “Optimización de la producción fotovoltaica con inteligencia artificial: predicción y detección de fallos más precisos,” <https://www.fcirce.es/blog/optimizacion-produccion-fotovoltaica-con-inteligencia-artificial>, 2024, recuperado el 20 de junio de 2026.
- [13] Iberdrola, “¿qué es la energía solar fotovoltaica y cómo funciona?” <https://www.iberdrola.com/conocenos/generacion-electrica-power/energia-solar-fotovoltaica>, 2026, recuperado el 19 de febrero de 2026.
- [14] Repsol, “Energía solar fotovoltaica: qué es y ventajas,” <https://www.repsol.es/particulares/asesoramiento-consumo/energia-solar-fotovoltaica/>, 2026, recuperado el 16 de febrero de 2026.
- [15] Konery, “¿qué es un inversor fotovoltaico y por qué es esencial?” <https://konery.com/que-es-un-inversor-fotovoltaico-y-por-que-es-esencial/>, 2026, recuperado el 17 de febrero de 2026.
- [16] G. Nassreddine, A. El Arid, M. Nassereddine, and O. Al Khatib, “Fault detection and classification for photovoltaic panel system using machine learning techniques,” *Applied AI Letters*, vol. 6, p. e115, 2025.

- [17] A. Khalid, N. Ullah, A. Riaz, M. Z. Zahir, and Z. Khan, "Detection and prediction of faults in photovoltaic solar panel using regression analysis," *Journal of Mechanical Engineering Research and Developments*, vol. 44, pp. 34–49, 10 2021.
- [18] T. AlSkaif, S. Dev, L. Visser, M. Hossari, and W. van Sark, "A systematic analysis of meteorological variables for PV output power estimation," *Renewable Energy*, vol. 153, pp. 12–22, 2020.
- [19] J. O. Ramsay and B. W. Silverman, *Functional Data Analysis*, 2nd ed. New York: Springer, 2005.
- [20] M. Febrero-Bande and M. Oviedo de la Fuente, "Statistical computing in functional data analysis: the R package fda.usc," *Journal of Statistical Software*, vol. 51, no. 4, pp. 1–28, 2012.
- [21] J. R. Sosa Donoso, M. Flores, S. Naya, and J. Tarrío-Saavedra, "Local correlation integral approach for anomaly detection using functional data," *Mathematics*, vol. 11, no. 4, p. 815, 2023.
- [22] M. Sánchez Allegue, "Estudio de la producción fotovoltaica en la Universidade da Coruña a partir de datos funcionales," Trabajo de Fin de Grado, Universidade da Coruña, 2025.
- [23] R. A. Johnson and D. W. Wichern, *Applied multivariate statistical analysis*, 6th ed. Prentice Hall, 2007.
- [24] R. E. Walpole, *Probabilidad y estadística para ingeniería y ciencias*, 9th ed. Pearson, 2012.
- [25] G. J. Székely, M. L. Rizzo, and N. K. Bakirov, "Measuring and testing dependence by correlation of distances," *The Annals of Statistics*, vol. 35, no. 6, pp. 2769–2794, 2007.
- [26] M. M. Breunig, H.-P. Kriegel, R. T. Ng, and J. Sander, "LOF: identifying density-based local outliers," in *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*. Dallas, Texas, USA: ACM, 2000, pp. 93–104.
- [27] I. T. Jolliffe, *Principal Component Analysis*, 2nd ed., ser. Springer Series in Statistics. New York, NY: Springer New York, 2002.
- [28] W. K. Härdle and L. Simar, *Applied Multivariate Statistical Analysis*, 5th ed. Springer Nature Switzerland AG, 2019.
- [29] K. V. Mardia, J. Bibby, and J. T. Kent, *Multivariate analysis*. Academic Press, 1979.

- [30] J. MacQueen, "Some methods for classification and analysis of multivariate observations," in *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, vol. 1. Berkeley, CA: University of California Press, 1967, pp. 281–297.
- [31] S. P. Lloyd, "Least squares quantization in PCM," *IEEE Transactions on Information Theory*, vol. 28, no. 2, pp. 129–137, 1982, trabajo original de 1957, publicado en 1982.
- [32] J. J. Faraway, *Extending the Linear Model with R: Generalized Linear, Mixed Effects and Nonparametric Regression Models*, 2nd ed. Boca Raton, FL: CRC Press, Taylor & Francis Group, 2016.
- [33] D. C. Montgomery, E. A. Peck, and G. G. Vining, *Introduction to Linear Regression Analysis*, 6th ed., ser. Wiley Series in Probability and Statistics. Hoboken, NJ: John Wiley & Sons, 2021.
- [34] D. A. Belsley, E. Kuh, and R. E. Welsch, *Regression Diagnostics: Identifying Influential Data and Sources of Collinearity*, 2nd ed. New York: Wiley, 1991.
- [35] D. W. Marquardt, "Generalized inverses, ridge regression, biased linear estimation, and nonlinear estimation," *Technometrics*, vol. 12, no. 3, pp. 591–612, 1970.
- [36] R. M. O'Brien, "A caution regarding rules of thumb for variance inflation factors," *Quality & Quantity*, vol. 41, no. 5, pp. 673–690, 2007.
- [37] C. L. Mallows, "Some comments on C_p ," *Technometrics*, vol. 15, no. 4, pp. 661–675, 1973.
- [38] H. Akaike, "A new look at the statistical model identification," *IEEE Transactions on Automatic Control*, vol. 19, no. 6, pp. 716–723, 1974.
- [39] G. Schwarz, "Estimating the dimension of a model," *The Annals of Statistics*, vol. 6, no. 2, pp. 461–464, 1978.
- [40] H. W. Lilliefors, "On the Kolmogorov-Smirnov test for normality with mean and variance unknown," *Journal of the American Statistical Association*, vol. 62, no. 318, pp. 399–402, 1967.
- [41] T. S. Breusch and A. R. Pagan, "A simple test for heteroscedasticity and random coefficient variation," *Econometrica*, vol. 47, no. 5, pp. 1287–1294, 1979.
- [42] A. Wald and J. Wolfowitz, "On a test whether two samples are from the same population," *The Annals of Mathematical Statistics*, vol. 11, no. 2, pp. 147–162, 1940.
- [43] R. D. Cook, "Detection of influential observation in linear regression," *Technometrics*, vol. 19, no. 1, pp. 15–18, 1977.

- [44] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [45] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. New York: Springer, 2009.
- [46] F. Ferraty and P. Vieu, *Nonparametric Functional Data Analysis: Theory and Practice*, ser. Springer Series in Statistics. New York: Springer, 2006.
- [47] M. Febrero-Bande and M. Oviedo de la Fuente, “Análisis de datos funcionales: un enfoque computacional,” 2025, manuscrito de curso, Universidade de Santiago de Compostela / Universidade da Coruña.
- [48] R. Fraiman and G. Muniz, “Trimmed means for functional data,” *TEST*, vol. 10, no. 2, pp. 419–440, 2001.
- [49] A. Cuevas, M. Febrero, and R. Fraiman, “Robust estimation and classification for functional data via projection-based depth notions,” *Computational Statistics*, vol. 22, no. 3, pp. 481–496, 2007.
- [50] H. Cardot, F. Ferraty, and P. Sarda, “Functional linear model,” *Statistics & Probability Letters*, vol. 45, no. 1, pp. 11–22, 1999.
- [51] P. Hall, H.-G. Müller, and J.-L. Wang, “Properties of principal component methods for functional and longitudinal data analysis,” *The Annals of Statistics*, vol. 34, no. 3, pp. 1493–1517, 2006.
- [52] P. T. Reiss, J. Goldsmith, H. L. Shang, and R. T. Ogden, “Methods for scalar-on-function regression,” *International Statistical Review*, vol. 85, no. 2, pp. 228–249, 2017.
- [53] R. Wirth and J. Hipp, “CRISP-DM: Towards a standard process model for data mining,” in *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, Manchester, UK, 2000, pp. 29–40.
- [54] R Core Team, *R: a language and environment for statistical computing*, <https://www.r-project.org/>, R Foundation for Statistical Computing, Vienna, Austria, 2024.
- [55] Posit Team, *RStudio: Integrated Development Environment for R*, Posit Software, PBC, Boston, MA, 2025. [En línea]. Disponible en: <http://www.rstudio.com/>
- [56] L. Lamport, *TEX: A Document Preparation System*, 2nd ed. Addison-Wesley, 1994.
- [57] Overleaf, “Overleaf: collaborative cloud-based TEX editor,” <https://www.overleaf.com/>, 2024, recuperado el 9 de junio de 2026.

- [58] Glassdoor, “Sueldos de ingeniero de datos junior en españa,” https://www.glassdoor.es/Sueldos/espa%C3%B1a-ingeniero-de-datos-junior-sueldo-SRCH_IL.0,6_KO7,32_IP2.htm, 2026, recuperado el 2 de junio de 2026.
- [59] Departamento de Inversiones, Navantia Ría de Ferrol, “Documentación técnica e información interna sobre la planta fotovoltaica del taller de reparaciones,” 2026, comunicación personal y acceso a especificaciones técnicas de los equipos. Documento no publicado.
- [60] MeteoGalicia, “Rede de observación meteorológica: datos históricos,” <https://www.meteogalicia.gal/web/observacion/rede-meteorologica/historico>, 2026, consellería de Medio Ambiente e Cambio Climático, Xunta de Galicia, recuperado el 5 de marzo de 2026.
- [61] MeteoGalicia, “Estación meteorológica: CIS ferrol (10050),” <https://www.meteogalicia.gal/web/observacion/rede-meteorologica?idEstacion=10050>, 2026, consellería de Medio Ambiente e Cambio Climático, Xunta de Galicia, recuperado el 5 de marzo de 2026.
- [62] T. Facchinetti, E. Ogliari, and A. Nespoli, “Tailored algorithms for anomaly detection in photovoltaic systems,” *Energies*, vol. 13, no. 1, p. 225, 2020. [En línea]. Disponible en: <https://www.mdpi.com/1996-1073/13/1/225>
- [63] Instituto Geográfico Nacional, “Clima: ATLAS Nacional de España,” <https://atlasnacional.ign.es/wane/Clima>, 2026, recuperado el 6 de marzo de 2026.
- [64] Escuela de Datos, “Estadística avanzada: detectando valores atípicos y datos inconsistentes,” <https://escueladedatos.online/tutorial/estadistica-avanzada-detectando-valores-atipicos-y-datos-inconsistentes/>, 2024, recuperado el 7 de abril de 2026.
- [65] MeteoGalicia, “Datos climatológicos,” <https://www.meteogalicia.gal/web/clima/datos-climatologicos>, 2026, consellería de Medio Ambiente e Cambio Climático, Xunta de Galicia, recuperado el 10 de marzo de 2026.
- [66] M. N. Wright and A. Ziegler, “ranger: A fast implementation of random forests for high dimensional data in C++ and R,” *Journal of Statistical Software*, vol. 77, no. 1, pp. 1–17, 2017.
- [67] M. Febrero, P. Galeano, and W. González-Manteiga, “Outlier detection in functional data by depth measures, with application to identify abnormal NOx levels,” *Environmetrics*, vol. 19, no. 4, pp. 331–345, 2008.